

ÉCOLE NATIONALE DES CHARTES
UNIVERSITÉ PARIS, SCIENCES & LETTRES

Joël Féral

licencié ès lettres

diplômé de master

L’outil Mezanno pour les approches quantitatives en sciences humaines et sociales

**De l’élaboration d’un corpus de documents
sériel à l’extraction automatisée de données
structurées : les tables annuelles du
Journal Officiel (1931 - 1935) comme cas
d’usage**

Mémoire pour le diplôme de master
« Technologies numériques appliquées à l’histoire »

2025

Résumé

Résumé du mémoire en français. Cette page ne doit pas dépasser une page.

Mots-clés : Journal Officiel ; Sénat ; Génération structurée ; LLM ; Mezanno ; séparés par des points-virgules.

Informations bibliographiques : Prénom Nom, *Titre du mémoire. Sous-titre du mémoire*, mémoire de master « Technologies numériques appliquées à l’histoire », dir. [Noms des directeurs.trices], École nationale des chartes, 20245.

Remerciements

MES remerciements vont tout d'abord à Jean-Philippe M., Joseph C., Marie P. et Sébastien C. qui m'ont fait confiance pour participer à l'élaboration du projet Mezanno.
Je remercie également mes parents ET SURTOUT DGETTO !!!

Bibliographie

Méthodologie historique

DAUMARD (Adeline) et FURET (François), « Méthodes de l'Histoire sociale : les Archives notariales et la Mécanographie », *Annales*, 14-4 (1959), Company : Persée - Portail des revues scientifiques en SHS Distributor : Persée - Portail des revues scientifiques en SHS Institution : Persée - Portail des revues scientifiques en SHS Label : Persée - Portail des revues scientifiques en SHS Publisher : EHESS, p. 676-693, DOI : 10.3406/ahess.1959.2865.

LEMERCIER (Claire) et ZALC (Claire), *Méthodes quantitatives pour l'historien*, ISSN : 0993-7625, 2008, DOI : 10.3917/dec.lemer.2008.01.

MÜLLER (Bertrand), « De la formation d'un concept à l'invention d'une tradition : les avatars de l'histoire sérielle », dans *Un historien dans ses lendemains : Pierre Chaunu*, dir. Denis Crouzet et Alain Hugon, Code : Un historien dans ses lendemains : Pierre Chaunu, Caen, 2021 (Symposia), DOI : 10.4000/books.puc.15437.

VAN CAMPENHOUDT (Marc), « Une norme de dépouillement terminologique en langue française », *Equivalences*, 21-1 (1992), Publisher : Persée - Portail des revues scientifiques en SHS, p. 121-136, DOI : 10.3406/equiv.1992.1147.

Institutions et politiques patrimoniales

BÉQUET (Gaëlle), « La bibliothèque numérique à la Bibliothèque de France : de l'objet-valise à l'objet-frontière (1988-1993) », dans *Trois bibliothèques européennes face à Google : Aux origines de la bibliothèque numérique (1990-2010)*, Code : Trois bibliothèques européennes face à Google : Aux origines de la bibliothèque numérique (1990-2010), Paris, 2015 (Mémoires et documents de l'École des chartes), p. 51-85, DOI : 10.4000/books.enc.14133.

BERMÈS (Emmanuelle), *De l'écran à l'émotion : quand le numérique devient patrimoine*, Country : FR 20 cm. PSL = Université Paris sciences & lettres. Bibliogr. p. 231-234. Index., Paris, 2024, URL : 893734 (visité le 22/08/2025).

- RAUTENBERG (Michel), « Les chemins croisés du patrimoine et de l’imaginaire », dans *L’imaginaire patrimonial : Figures de l’urbanité contemporaine*, Code : L’imaginaire patrimonial : Figures de l’urbanité contemporaine, Rennes, 2024 (Essais), p. 13-52, DOI : 10.4000/13ipp.
- WAGNEUR (Jean-Didier), « Gallica : la bibliothèque électronique de la BnF : quel accès pour les personnes handicapées visuelles ? », dans *Bibliothèques et publics handicapés visuels*, Code : Bibliothèques et publics handicapés visuels, Paris, 2002 (Paroles en réseau), DOI : 10.4000/books.bibpompidou.1500.

Humanités numériques

- CLAVERT (Frédéric), « Une histoire par les données ? Le futur très proche de l’histoire des relations internationales », *Bulletin de l’Institut Pierre Renouvin*, 44-2 (nov. 2016), Publisher : UMR Sirice Section : Histoire, p. 119-130, DOI : 10.3917/bipr1.044.0119.
- *Le goût de l’API / Le goût de l’archive à l’ère numérique*, fr-FR, URL : <https://gout-numerique.net/table-of-contents/archives-nees-numeriques/gout-api> (visité le 22/08/2025).
- DENIS (Jérôme) et GOËTA (Samuel), « Les facettes de l’Open Data : émergence, fondements et travail en coulisses », dans *Big data et traçabilité numérique : Les sciences sociales face à la quantification massive des individus*, dir. Pierre-Michel Menger et Simon Paye, Code : Big data et traçabilité numérique : Les sciences sociales face à la quantification massive des individus, Paris, 2017 (Conférences), p. 121-138, DOI : 10.4000/books.cdf.5005.
- DEROSE (Steven J.), DURAND (David G.), MYLONAS (Elli) et RENEAR (Allen H.), « What is text, really ? », *Journal of Computing in Higher Education*, 1-2 (déc. 1990), p. 3-26, DOI : 10.1007/BF02941632.
- DRUCKER (Johanna), *Visualisation. L’interprétation modélisante*, B42, Paris, 2020.
- MANUEFIG, *Numériser ce n’est pas éditer (2)*, fr-FR, janv. 2005, URL : <https://figoblog.org/2005/01/18/519/> (visité le 20/08/2025).
- POUBLANC (Sébastien) et MARQUÉ (Nicolas), « Introduction au dossier « Historien·nes et numérique : pratiques et expériences vécues » », *Les Cahiers de Framespa. e-STORIA*—42 (juill. 2023), Publisher : UMR 5136 – FRAMESPA, DOI : 10.4000/framespa.14370.

Images et numérisation

- CASEY (R.G.) et LECOLINET (E.), « A survey of methods and strategies in character segmentation », *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 18–7 (juill. 1996), p. 690-706, DOI : 10.1109/34.506792.
- CHIRON (Guillaume), MOREUX (Jean-Philippe), DOUCET (Antoine), COUSTATY (Mickaël) et VISANI (Muriel), « Erreurs OCR et biais d’indexation : impact sur les usages », dans *17ème conférence Extraction et Gestion des Connaissances, Atelier Journalisme Computationnel*, Grenoble, France, 2017, p. 69-73, URL : <https://hal.science/hal-01455763> (visité le 22/08/2025).
- Thierry Claerr et Isabelle Westeel (éd.), *Numériser et mettre en ligne*, Code : Numériser et mettre en ligne Publication Title : Numériser et mettre en ligne Reporter : Numériser et mettre en ligne Series Title : La Boîte à outils, Villeurbanne, 2010 (La Boîte à outils), URL : <https://books.openedition.org/pressesenssib/414> (visité le 20/08/2025).
- KIESSLING (Benjamin), « Kraken - A Universal Text Recognizer for the Humanities », dans *Digital Humanities 2019*, Utrecht, Netherlands, 2019, DOI : 10.34894/Z9G2EX.
- LEBERT (Marie), *gutenberg.org/cache/epub/27040/pg27040.txt*, URL : <https://www.gutenberg.org/cache/epub/27040/pg27040.txt> (visité le 17/08/2025).
- Mistral OCR / Mistral AI*, en, URL : <https://urlr.me/Cqyt9c> (visité le 21/08/2025).
- SMITH (R.), « An Overview of the Tesseract OCR Engine », dans *Ninth International Conference on Document Analysis and Recognition (ICDAR 2007) Vol 2*, ISSN : 1520-5363, Curitiba, Parana, Brazil, 2007, p. 629-633, DOI : 10.1109/ICDAR.2007.4376991.
- SMITH (Ray W.), « History of the Tesseract OCR engine : what worked and what didn’t », dans ADS Bibcode : 2013SPIE.8658E..02S, 2013, t. 8658, p. 865802, DOI : 10.1117/12.2010051.

Traitement automatique du langage

- FINKEL (Jenny Rose), GRENAGER (Trond) et MANNING (Christopher), « Incorporating Non-local Information into Information Extraction Systems by Gibbs Sampling », dans *Proceedings of the 43rd Annual Meeting of the Association for Computational Linguistics (ACL’05)*, dir. Kevin Knight, Hwee Tou Ng et Kemal Oflazer, Ann Arbor, Michigan, 2005, p. 363-370, DOI : 10.3115/1219840.1219885.
- GRAHAM (S. Scott), MAJDIK (Zoltan P.) et CLARK (Dave), « Methods for Extracting Relational Data from Unstructured Texts Prior to Network Visualization in Humanities Research », *Journal of Open Humanities Data*, 6–1 (nov. 2020), DOI : 10.5334/johd.21.

- GRAVES (Alex), FERNANDEZ (Santiago), GOMEZ (Faustino) et SCHMIDHUBER (Jurgen), « Connectionist Temporal Classification : Labelling Unsegmented Sequence Data with Recurrent Neural Networks » ().
- RADFORD (Alec), NARASIMHAN (Karthik), SALIMANS (Tim) et SUTSKEVER (Ilya), « Improving Language Understanding by Generative Pre-Training » ().

Philosophie de la technique et médialité

- BERT (Jean-François), *Une histoire de la fiche érudite*, Code : Une histoire de la fiche érudite Publication Title : Une histoire de la fiche érudite Reporter : Une histoire de la fiche érudite Series Title : Papiers, Villeurbanne, 2017 (Papiers), URL : <https://books.openedition.org/pressesenssib/6211> (visité le 21/08/2025).
- BOISSIER (Jean-Louis), *La relation comme forme*, Les Presses du Réel, Dijon, 2009.
- BONTEMS (Vincent), « Sur la classification des objets techniques selon Simondon », *Artefact. Techniques, histoire et sciences humaines*–3 (mars 2016), ISBN : 9782271087539 Number : 3 Publisher : Presses universitaires du Midi, p. 183-198, DOI : 10.4000/artefact.8270.
- Jean-Marie Dallet et Bertrand Gervais (éd.), *Architectures de mémoire*, Code : Architectures de mémoire Publication Title : Architectures de mémoire Reporter : Architectures de mémoire Series Title : La Grande Collection ArTeC, Nanterre, 2019 (La Grande Collection ArTeC), URL : <https://books.openedition.org/pupo/25762> (visité le 20/08/2025).
- DASTON (Lorraine) et GALISON (Peter), *Objectivité*, Les Presses du Réel, Dijon, 2012.
- DEWEY (John), *La formation des valeurs*, La Découverte, Paris, 2011.
- LEVI-STRAUSS (Claude), *La pensée sauvage*.
- RENON (Anne-Lyse), *Design & sciences*, fr-FR, URL : <https://www.puv-editions.fr/ouvrage/design-sciences/> (visité le 22/08/2025).
- SIMODON (Gilbert), *Du mode d'existence des objets techniques*, Aubier, 1958.

*Remuer du papier ne peut pas
être inutile.*

Bruno Latour

Introduction

Pour l'historien, les archives font figure centrale [Jean Boutier]. Pour répondre à une question de recherche, le chercheur va dépouiller, trier, classer, reclasser, recouper les documents ou les données issus de fonds ou de collections recueillies. Cette matière se constitue alors en corpus pour ajuster des questions ou charpenter des réponses. Dans l'épars documentaire s'esquissent des hypothèses, s'élaborent des solutions. L'information enfin extraite des cartons, des rayons ou des documents disponibles sur le Web peut être enfin convoquée, parfois après un laborieux travail de dépouillement. Avec un peu de chance, l'information s'offre presque toute prête : ainsi les lignes budgétaires de tel livre de compte de telle institution ; ainsi telles entrées de tels annuaires professionnels. Tantôt il faudra reproduire manuellement l'information qui a été dénichée feuille à feuille et parfois photographiée à la hâte ; tantôt, avec un peu plus de chance, simplement récupérer des jeux de données quasiment prêts à l'emploi et les traiter selon ce qu'exige les impératifs scientifiques. Une fois les données réunies en lignes et en tableaux, l'enquête ne fait que commencer : c'est qu'il s'agit de supposer des tendances, des points de comparaison ; de dégager aux événements des séries ou des structures explicatives et forger des réponses. Ainsi la "centralité de l'archive" – et des données – dans le travail de l'historien – hier Lucien Febvre, Prost.. – ou du sociologue – Durkheim – ou encore, pourquoi pas, de l'astronome et ses archives voulant restituer un passé aux trajectoires des comètes.

Derrière ces masses de documents sériels, une allure : ce sont des bases de données de papier. Elles contiennent des noms et des nombres, des métiers ou des adresses. Pour le chercheur, ces sources répétitives se prêtent volontiers à une traduction numérique pour faciliter et opérer des traitements plus systématiques en bénéficiant des capacités calculatoires de l'ordinateur. Egaleme nt pour l'archiviste en charge de l'indexation des fonds, elles regorgent de noms qu'il est intéressant d'exposer, par exemple, à son public de généalogistes via les portails de recherche d'archives. Naturellement, il est tenté d'employer l'outil informatique pour déléguer – ou rendre possible – ce travail d'extraction et de structuration de l'information présente dans les masses documentaires. Les grands modèles de langue (les *LLM*) semblent pouvoir faire endosser aux ordinateurs ce labeur de traduction et de structuration

de l'information. Se dessinent alors des enjeux techniques et épistémologiques d'un passage – celui des documents « analogiques » aux données numériques – qu'il convient d'interroger.

Ce mémoire interroge la problématique de la traduction de ces corpus sériels en ensembles de données structurées, dans une perspective d'analyse historique et archivistique. Historienne d'abord, car il s'agit d'explorer de "nouvelles frontières" disciplinaires impliquant la collaboration entre chercheurs en SHS, informaticiens et institutions patrimoniales en vue d'exploiter à des fins scientifiques des données issus de fonds numérisés ; archivistique ensuite, car la traduction des informations contenues dans les documents en données exploitables par des systèmes informatiques rejoignent les enjeux d'indexation et donc de valorisation d'ensembles documentaires.

Cette problématique de traduction de fonds sériels en données structurées exploitables pour l'analyse quantitative historique ou pour la valorisation documentaire part d'un constat : nombre de publications administratives ou normatives — annuaires, lois, décrets, tables parlementaires — relèvent d'une production sérielle à forte teneur informationnelle mais échappent aux catégories sensibles habituellement mobilisées dans le rapport aux archives. Leur lecture manuelle est difficile, leur dépouillement peut être décourageant. On s'éloigne ici du "goût de l'archive" d'Arlette Farge qui dépeint une phénoménologie sensible de la source historique pour adopter une approche moins solipsiste de valorisation de documents "sans goût" – mais dont on aura restitué un pluriel. Ces fonds sériels – dont il est difficile de valoriser au même titre que de prestigieuses chartes médiévales ou de précises gravures scientifiques étant donné leur monotone prosaïsme – forment en effet une mémoire institutionnelle précieuse qu'il convient d'interroger dès lors qu'on parvient à les structurer et les croiser avec d'autres sources.

Si on n'arrête pas de louer depuis quelques décennies de nouveaux tournants dans la façon de travailler sur les sources grâce à l'outil numérique, il faut bien avouer que les derniers développements autour des grands modèles de langage accentuent un virage. La fouille de texte, la « lecture à distance » (*distance reading*), et tout ce qui implique l'extraction d'information sémantique, reposent sur une récente synergisation des techniques numériques : tout d'abord, la capacité à restituer un objet physique en image discrète (numérisation) ; de structurer et normaliser l'accès à des images dans des dépôts centralisés via des protocoles HTTP(API) ; de retranscrire de l'image l'information textuelle (OCR) ou des structures de pages (Document Layout Detection) ; et de la structuration sémantique *a posteriori* des entités nommées de façon semi-automatique – moyennement un apprentissage supervisé via l'annotation ou le moissonnage de la production scientifique en ligne, déjà numérisée. Cette synergie des traitements sur l'image numérique et des développement en linguistique computationnelle renouvelle « les frontières de l'historien » en ce sens que, pour peu que les

documents soient numérisées, on puisse automatiser le travail d'extraction de l'information présente dans les sources. La chaîne qui va de la numérisation du document à l'extraction de données sémantiquement structurées et son analyse via l'outil informatique forme un *système technique* (Simondon) et l'historien, le sociologue ou encore le statisticien s'y inscrivent pleinement.

Une précaution : la question technique qui participe de l'administration des nouvelles frontières de l'historien n'est pas seulement un moyen d'automatiser des tâches qui autrefois étaient plus manuelles : elle apporte dans ses rêts de nouveaux enjeux épistémologiques (les données ne se donnent pas, ce sont des *capta*, Drucker), des manières de réactiver des questions ou des réponses (Colingwood), des sources documentaires, des méthodes (impliquant une redivision du travail) ou des façons de travailler (Ladurie, l'historien et l'ordinateur). Les questions techniques sont moins une affaire d'automatisation que de sensibilité des systèmes techniques à l'information et leur relation avec le travail humain (Simondon). De même, les instruments ne font pas que servir le travail intellectuel de façon neutre : ils sont aussi de la « théorie réifiée » (Bachelard). Se superposent ainsi le champ énonciatif des systèmes techniques et des disciplines scientifiques qui s'y inscrivent et expriment des connaissances *situées*. Les outils techniques promettent des méthodologies – lesquelles reposent sur de manière d'envisager la division d'un travail pour une tâche déterminée. Les *pipelines* de traitement de données – de l'image au texte structuré – se constituent à la fois comme outil et comme condensation *in silicium* des *a priori* épistémologiques. Les solutions techniques à des problèmes scientifiques sont une affaire de *design* (Anne-Lyse Renon), c'est-à-dire de stratégies épistémiques et évaluatives.

Dès lors, comment articuler les enjeux historiographiques propres à ces corpus avec les nouvelles opportunités d'extraction et de structuration automatiques qu'offrent les techniques récentes et leur synergisation ? (OCR, modèles de langage, outils d'annotation) ? Comment construire une chaîne de traitement reproductible, capable de restituer la richesse de ces fonds tout en garantissant la qualité des données produites ? La question de la valuation des méthodes – c'est-à-dire de leur légitimité au regard de ce à quoi on tient savoir –, elle-même, semble dépendre des besoins : un archiviste n'a pas tout à fait les mêmes besoins qu'un historien – et tous les historiens n'ont pas les mêmes besoins. Pour le premier, l'exactitude est de mise ; pour le second qui adopte une approche statistique, des données fiables – c'est-à-dire probablement imparfaites – seront suffisantes pour effectuer des « pesées globales » historiques (Pierre Chaunu).

Ces questionnements auront été les miens durant mon stage à l'EPITA/BnF où j'ai eu l'occasion de travailler à la convergence des nouvelles opportunités de traitements automatiques et de la question de la légitimité épistémique de données produites par des systèmes

techniques, à partir de l'extraction d'informations sous forme structurée du Journal Officiel de 1931, dans une optique de préparation de l'analyse des discours historiques sous la IIIe République. [à développer]

Cette interrogation se décline ainsi selon ces trois axes :

- Que sont les sources sérielles et quels sont leurs apports spécifiques pour répondre à une question de recherche ? En quoi leur structure, leur cumulativité et leur forme normative permettent-elles des lectures nouvelles, notamment en lien avec les pratiques de gouvernement et les dispositifs de publicité du droit sous la IIIe République ? Pour aborder ce point, je me pencherai sur l'analyse des Tables du Sénat de 1931 car, dans une perspective de *reenactement* historien de l'activité parlementaire, elles donneraient un corps à cette problématique de traduction de sources sérielles en sources exploitables pour l'analyse.
- Quelles méthodes et quels outils permettent aujourd'hui d'en automatiser la structuration ? Comment construire un protocole d'extraction cohérent, tenant compte de la matérialité des documents (OCR, mise en page, bruit), des formats de sortie, et des finalités analytiques visées ?
- Comment évaluer la fiabilité des données ainsi produites et garantir leur légitimité scientifique ? Quels critères de qualité, de traçabilité et de transparence permettent de faire de ces résultats des objets d'enquête mobilisables par les historiens ?

A travers ces trois axes, qui constituent chacun une partie de ce mémoire, je veux donc répondre à la problématique du passage de l'information sérielle non-structurée présente dans les sources, à la fois sur des aspects documentaires ; techniques (méthodes d'extraction) et évaluatives (évaluation et épistémologie de l'évaluation).

Première partie

Des sources sérielles : les Tables Annuelles du Sénat comme cas d'usage

Chapitre 1

Le Journal Officiel : la parole, la main, la vue et le droit

Reencatement

1. Les sources sérielles : définition et enjeux

Les sources sérielles désignent des ensembles documentaires produits de manière régulière, cumulative et normalisée, qui permettent d’observer la répétition et l’évolution de phénomènes sociaux ou politiques dans le temps. Pierre Chaunu, qui en a popularisé l’usage dans les années 1960, les définissait comme des matériaux « à série longue », permettant une histoire quantitative de la conjoncture, qu’il s’agisse des prix, des registres paroissiaux ou des trafics maritimes. Dans la lignée de cette approche, Emmanuel Le Roy Ladurie a montré que la régularité et la masse de ces sources ouvraient la voie à une « histoire sérielle » fondée sur l’accumulation et le traitement statistique.

À l’ère numérique, des historiens comme Frédéric Clavert rappellent que ces sources se distinguent moins par leur nature que par leur mode de production : leur caractère répétitif, leur homogénéité formelle et leur relative standardisation les rendent propices à des opérations d’extraction et de structuration automatisées. En ce sens, elles ne livrent pas seulement des contenus, mais offrent un potentiel méthodologique, qui repose sur leur caractère cumulatif.

La sérialité documentaire ne doit cependant pas masquer la dimension éditoriale et institutionnelle de ces objets. Comme l’a montré Alain Desrosières pour les statistiques publiques, la constitution d’une série est toujours le résultat d’un choix social et politique : décider ce qui est compté, comment cela est classé, et pour quels usages. Appliqué aux sources parlementaires, ce constat invite à considérer que les tables du Journal Officiel ne sont pas de simples instruments techniques : elles orientent la lecture, hiérarchisent les thèmes et construisent

une représentation ordonnée de l'activité politique.

2. 1.1. Le *Journal Officiel* : entre publicité et promulgation

La création du *Journal Officiel de la République française* en 1869 s'inscrit dans une longue histoire des dispositifs de publicité de la loi. Héritier à la fois du *Moniteur universel* (1789–1869), qui transcrivait les débats parlementaires, et du *Bulletin des lois* (1793–1931), garant de la promulgation exécutoire des textes normatifs, le *Journal Officiel* cumule deux fonctions : informer le public des débats parlementaires et conférer force obligatoire aux lois par leur publication. Cette double vocation, attestée dès la Révolution française, fait de ce périodique un instrument essentiel de la transparence parlementaire et de l'effectivité juridique.

Son caractère sériel — une parution quasi quotidienne, au format stable, avec une organisation régulière des rubriques — constitue précisément ce qui en fait une source de premier plan pour l'historien. Sa régularité et sa cumulativité permettent de suivre à la trace l'activité parlementaire, mais elles posent aussi la question de la matérialité du texte publié : transcription fidèle ou recomposition éditoriale ? Dès lors, le *Journal Officiel* ne doit pas être lu seulement comme un réceptacle de la parole parlementaire, mais comme une œuvre éditoriale, façonnée par les sténographes, rédacteurs et correcteurs qui traduisent l'oralité en texte écrit.

3. 1.2. Archives ou documentation ? La place singulière du *Journal Officiel*

La nature archivistique du *Journal Officiel* demeure ambivalente. Juridiquement, il s'agit d'une publication soumise au dépôt légal, conservée à ce titre à la Bibliothèque nationale de France, à la bibliothèque des Assemblées et aux Archives nationales. Pourtant, son intégration dans la **série K des Archives départementales** interroge : peut-on considérer comme archives des documents produits à des fins éditoriales, vendus au public et destinés à être lus ?

L'analyse archivistique rappelle que les archives sont le « collatéral direct » d'une activité administrative, produites sans intention de publication. Or, le *Journal Officiel* est un objet éditorial dont la finalité première est précisément la publicité. Son inscription en série K — aux côtés des lois, ordonnances et arrêtés préfectoraux — illustre néanmoins la manière dont l'État a voulu garantir, dans chaque département, l'accès des citoyens aux textes normatifs. Loin d'être un simple effet du « respect des fonds », cette intégration témoigne d'une stratégie politique de diffusion centralisée du droit.

Cette tension entre document édité et document d’archives souligne la spécificité des sources sérielles : elles se situent à la frontière entre mémoire administrative et communication publique, entre traces institutionnelles et dispositifs de légitimation.

4. 1.3. Le *Journal Officiel* dans son contexte technique et administratif (1921–1940)

Pour comprendre la matérialité de la source exploitée dans ce mémoire (les tables du Sénat de 1931), il faut rappeler que le *Journal Officiel* n’était pas seulement le produit d’une Chambre parlementaire, mais celui d’une organisation industrielle. Depuis 1880, la publication est assurée par la **Société anonyme coopérative de composition et d’impression des Journaux officiels (SACIJO)**, placée sous tutelle du ministère de l’Intérieur. Linotypistes, rotativistes, correcteurs et personnels administratifs concourent à sa fabrication quotidienne.

La période 1921–1940, bornée par l’acquisition de la *linotype Model 9* et l’interruption de 1940, offre un cadre technique relativement homogène. Elle correspond aussi à une stabilité des pratiques éditoriales, qui permet d’envisager une lecture sérielle. Les archives de la Direction des Journaux officiels (série 19840069 des AN) éclairent cette fabrique administrative : rapports budgétaires, organigrammes, correspondances de service. Elles révèlent un fonctionnement hybride, entre administration d’État et entreprise de presse, qui explique la diffusion massive et régulière de ces volumes.

5. 1.4. Les « processus métier » de la publicité parlementaire

Qualifier la chaîne de production parlementaire en termes de « processus métier » revient à cartographier l’ensemble des opérations qui transforment la parole politique en texte normatif publié. À la IIIe République, ce processus suit plusieurs étapes :

* **Délibérer** : débats oraux au Sénat et à la Chambre des députés, régis par les règlements de 1876, avec une organisation en bureaux et commissions. **Transcrire** : *sténographes et rédacteurs produisent les comptes rendus in extenso**, qui passent par un travail de révision avant impression. **Publier** : *les textes sont édités dans le Journal Officiel** et diffusés par abonnement et dépôt légal. * **Promulguer** : la publication confère force obligatoire aux lois votées, qui ne prennent effet qu’une fois rendues publiques.

Ce continuum — délibérer, transcrire, publier, promulguer — rend manifeste le rôle central du *Journal Officiel*. Il ne s’agit pas seulement d’un témoin documentaire, mais d’un maillon de l’effectivité du droit.

Chapitre 2

Chapitre 2 — Les tables annuelles : des relations entre corpus

1. 2.1. Les tables dans l’environnement du *Journal Officiel*

À côté des livraisons quotidiennes du *Journal Officiel*, le dispositif documentaire de la Troisième République produit un ensemble d’outils de repérage et de cumul : index, tables et recueils annuels. Ces tables, organisées par Chambre et par type de document (séances, questions, interventions, lois, décrets, etc.), constituent un instrument de navigation à travers la masse documentaire accumulée. Elles offrent un second niveau de structuration, indispensable à l’exploitation d’un corpus qui, sans cela, serait pratiquement illisible dans son entier.

Dans ce sens, les tables ne sont pas de simples annexes, mais un élément constitutif du *Journal Officiel*. Leur publication témoigne d’une volonté de rendre praticable la lecture sérielle, en transformant un flot continu de débats en une matière consultable a posteriori. Elles permettent aux parlementaires, aux fonctionnaires et aux juristes, mais aussi aux journalistes et au public, de retrouver un débat, une loi ou un orateur dans un ensemble potentiellement infini de pages.

2. 2.2. Forme et organisation des tables

La table annuelle se présente comme un volume imprimé, distinct des numéros quotidiens mais reprenant la même logique typographique de sobriété. La structuration est généralement alphabétique ou thématique, avec des entrées renvoyant à des numéros de séance ou de page du *Journal Officiel*. Ainsi, le chercheur y trouve à la fois :

* des index de noms (parlementaires, ministres, orateurs) ; * des index de matières (projets de lois, sujets débattus, thèmes abordés) ; * des références législatives (dates, intitulés, numéros de lois et décrets).

Cette composition apparemment simple reflète un travail complexe de collecte et de mise en ordre, qui engage des méthodes d'indexation encore largement manuelles dans les années 1930. Les tables matérialisent donc une double médiation : celle de la transcription sténographique, puis celle de la mise en indexation.

3. 2.3. Informations sémantiques et usages

Les tables ne livrent pas seulement des renvois. Leur organisation alphabétique ou thématique suggère déjà une lecture orientée du corpus. En réordonnant les débats selon les sujets ou les personnes, elles produisent une représentation « secondaire » de l'activité parlementaire :

* **Pour l'historien**, elles permettent de cartographier les thèmes récurrents, d'identifier des trajectoires individuelles de parlementaires, ou encore de suivre la maturation d'une question dans le temps long. * **Pour les juristes**, elles assurent un repérage efficace des textes normatifs, condition de la sécurité juridique. * **Pour l'administration**, elles facilitent la réutilisation interne des débats et la circulation de l'information entre services.

En ce sens, les tables possèdent une valeur sémantique propre : elles ne sont pas de simples index, mais des instruments de catégorisation, qui hiérarchisent les contenus du *Journal Officiel* et leur confèrent une visibilité inégale.

4. 2.4. Les tables comme « hub » intercorpus

Enfin, les tables établissent des liens entre différents ensembles documentaires. Elles ne se limitent pas aux seuls débats parlementaires, mais relient ceux-ci aux autres publications officielles et à des corpus complémentaires. Elles servent d'articulation entre :

*les volumes quotidiens du Journal Officiel** ; *les recueils législatifs et réglementaires (par exemple le Bulletin des lois*)* ; * les instruments internes des Chambres (procès-verbaux, rapports de commissions) ; * les archives départementales (série K), où elles prennent place aux côtés d'autres formes de publicité administrative.

En occupant cette position nodale, les tables fonctionnent comme des « hubs documentaires » : elles permettent de passer d'un corpus à l'autre, et d'inscrire les débats dans l'écosystème plus large des pratiques de gouvernement.

5. Exemple : Les Tables du Sénat, année 1931

Le volume des *Tables annuelles du Sénat* pour l'année 1931 se présente sous la forme d'un in-octavo relié, composé de plusieurs centaines de pages. La typographie, sobre et régu-

lière, reprend les conventions du *Journal Officiel* : colonnes étroites, numérotation continue, absence d'ornementation. L'ensemble se divise en sections distinctes, qui reflètent les usages concrets des lecteurs.

a. 1. Index des orateurs

On y trouve une **liste alphabétique des sénateurs**, chaque nom suivi de références aux séances où ils sont intervenus. Par exemple :

Tardieu (André) : interventions p. 312, 457, 892.

Cet index permet de retracer rapidement la présence et l'activité d'un parlementaire sur une année complète. Pour l'historien, il offre une base sérielle pour mesurer la visibilité des élus et la fréquence de leur participation aux débats.

b. 2. Table des matières thématiques

La deuxième section regroupe les débats par **matières** :

Finances publiques* : budget, impôts, emprunts. Affaires étrangères* : traités, conventions, mandats. Travail et questions sociales* : assurance chômage, législation ouvrière, retraites.

Chaque entrée renvoie à un numéro de séance du *Journal Officiel*. Ce classement thématique reflète une logique documentaire propre, qui diffère de l'ordre chronologique des séances : il met en valeur la récurrence des thèmes et facilite leur repérage transversal.

c. 3. Références législatives et réglementaires

Enfin, les tables recensent les **lois votées et les décrets publiés** pendant l'année, assortis de leur date et de leur numéro. Ce registre, proche d'un répertoire législatif, assure le lien avec le *Bulletin des lois* et, par extension, avec l'ensemble de la législation nationale.

6. Analyse

Cet exemple illustre trois dimensions essentielles des tables :

* Leur **fonction instrumentale** : elles servent avant tout de guide, destiné à faciliter la recherche d'une information précise dans un corpus immense. * Leur **valeur sémantique** : en proposant une catégorisation (par personnes, thèmes, textes), elles produisent une image de l'activité parlementaire qui n'est pas neutre, mais orientée par le mode d'indexation. * Leur **rôle intercorpus** : en mettant en relation débats, interventions et textes normatifs, elles constituent un point de jonction entre la parole parlementaire et le droit promulgué.

7. Numérisation du *Journal Officiel* : entre politique documentaire, infrastructures techniques et souveraineté archivistique

Du côté de la BnF, avec le projet Gallica, c'est le « mode image » qui a été choisi : « la bibliothèque se range pour de bon du côté de la reproduction plutôt que de l'édition ».

La numérisation du *Journal Officiel de la République française* (J.O.) constitue un cas exemplaire des tensions de la datafication. Sa mise en ligne sur **Gallica**, la bibliothèque numérique de la BnF, n'est pas seulement le produit d'une opération technique (scanner, OCR, structurer) : elle relève d'une **politique documentaire explicite**, d'une hiérarchie patrimoniale et d'une réflexion sur la transparence démocratique.

Dès le lancement de Gallica dans les années 1990, les corpus officiels et juridiques ont été considérés comme prioritaires dans les programmes de numérisation. La BnF a défini une **politique de numérisation concertée** qui associe ses partenaires institutionnels (bibliothèques, archives, musées, mais aussi administrations parlementaires) et repose sur deux modalités principales :

* la **subvention**, qui permet à des institutions tierces de financer la numérisation de leurs fonds à condition que les résultats soient interoperables et intégrés dans Gallica ; *l'intégration directe dans le marché de numérisation de la BnF, réservée aux corpus volumineux ou emblématiques, comme le Journal Officiel*

Deuxième partie

L'enjeu des données structurées : des sources à la base de données

Chapitre 3

Une histoire par les données

Les *Tables Annuelles* du Sénat, comme on vient de le voir, contiennent une véritable mine d'informations pour établir une analyse de l'activité parlementaire. Ces *Tables*, accessibles sur Gallica, avec le jeu des renvois et des index, sont de véritables bases de données de papier numérisées. Pour récupérer les informations du *Journal Officiel* de façon automatisée, c'est-à-dire sans reproduire à la main l'ensemble, il faut penser à une chaîne de traitement qui part de ces sources numériques, sous format image, pour pouvoir en capturer l'information. Il s'agit ici de voir comment construire un protocole d'extraction cohérent, en tenant compte de la matérialité des documents eux-mêmes, aussi bien sous leur forme « analogique » que numérique.

Dans ce chapitre, il s'agira de répondre aux problématiques technique de cette traduction des sources numérisées – c'est-à-dire sous format image – au texte. Ceci imposant de donner un contexte préalable de cette « mise en données »¹ des sources historiques, laquelle est inhérente à la disponibilité de corpus numérisés par les politiques de valorisation des fonds des institutions patrimoniales. [Section 1 : Datafication des corpus : « numériser »]

Ensuite, premier problème : comment travailler à partir d'une image numérique ? Certes, la représentation photographique et numérique d'un document est lisible pour un œil humain ; mais du point de vue informationnel, ces images ne sont que des paquets de pixels, une conversion numérique de l'information lumineuse renvoyée par les objets photographiés². Ces pixels ne sont pas, évidemment, les lettres elles-mêmes. Ils sont la traduction sur l'écran de trains d'informations binaires qui, sans le bon décodage, pourrait vouloir dire tout autre chose.

¹Frédéric Clavert, « Une histoire par les données ? Le futur très proche de l'histoire des relations internationales », *Bulletin de l'Institut Pierre Renouvin*, 44-2 (nov. 2016), Publisher : UMR Sirice Section : Histoire, p. 119-130, DOI : 10.3917/bipr1.044.0119.

²Thierry Claerr et Isabelle Westeel (éd.), *Numériser et mettre en ligne*, Code : Numériser et mettre en ligne Publication Title : Numériser et mettre en ligne Reporter : Numériser et mettre en ligne Series Title : La Boîte à outils, Villeurbanne, 2010 (La Boîte à outils), URL : <https://books.openedition.org/pressesenssib/414> (visité le 20/08/2025).

Le premier enjeu pour un travail de capture de l'information est de transformer cette matière matricielle en information textuelle sur laquelle on peut appliquer des traitements. Le texte se présente comme pré-requis pour établir des chaînes de traitement de capture informationnelle. Ce passage de l'image au texte numérique est en fait techniquement une prérogative des tâches de *reconnaissance optique des caractères* – ou « OCR » (Optical Character Recognition). Elle butte également sur des problématiques de détection de la mise en page, laquelle fonde un ordre de lecture – et donc un agencement du sens des phrases qu'il faut considérer. [Section 2 : de l'image au texte]

Deuxième problème : une fois ce texte numérique obtenu, comment capturer l'information sémantique qui est présente ? Comment l'ordinateur peut comprendre que tel ensemble des caractères alphanumériques correspond en fait à un sénateur de la Troisième République ? On peut trouver, dans le document, des motifs qui signalent une entité (par exemple, un sénateur inaugure chaque paragraphe). Cette approche comme on va le voir, est basée sur la reconnaissance de motifs typographiques. Elle est cependant fragile et dépendante de la qualité de l'OCR – voire des erreurs humaines présentes dans le document d'origine. Elle suppose aussi une forme de connaissance *a priori* synthétique de la représentation de l'information dans le document. Ainsi peut-on se tourner vers des approches extractives qui viennent labeliser l'information textuelle obtenue³ ; ou bien les approches génératives qui « lisent » le texte et restituent l'information comprise et permettent de contourner le problème des exceptions qui forment le corps des documents⁴. Cette chaîne de travail de capture exige une information exploitable par l'ordinateur ; elle a besoin d'une certaine systémacité, laquelle est une prérogative des modèles de données – de leur « forme ». La chaîne de traitement commence donc avec l'image, passe par le texte et des méthodes de capture de l'information sémantique qu'elle contient, pour aboutir à une information structurée. L'enjeu n'est pas simple car chaque étape reporte les marges d'erreur des précédentes. [Section 3]

Dans ce chapitre, il s'agira ainsi de dessiner le contexte technique et institutionnel de cette datafication des données en vue de leur traitement – et notamment avec les nouvelles opportunités des grands modèles de langage.

³Jenny Rose Finkel, Trond Grenager et Christopher Manning, « Incorporating Non-local Information into Information Extraction Systems by Gibbs Sampling », dans *Proceedings of the 43rd Annual Meeting of the Association for Computational Linguistics (ACL'05)*, dir. Kevin Knight, Hwee Tou Ng et Kemal Oflazer, Ann Arbor, Michigan, 2005, p. 363-370, DOI : 10.3115/1219840.1219885.

⁴Alec Radford, Karthik Narasimhan, Tim Salimans et Ilya Sutskever, « Improving Language Understanding by Generative Pre-Training » ().

I. Numériser les sources

1. En « mode texte »

En 1971, un étudiant, reproduisait sur un ordinateur *Xerox* la *Déclaration d'indépendance des Etats-Unis*, en caractères alphanumériques **ASCII**. Il s'agissait de Michel Hart, fondateur du **Projet Gutenberg** qui se donnait pour tâche de reproduire et diffuser bénévolement sur le réseau internet des oeuvres littéraires du domaine public. Des livres comme *La Bible*, des oeuvres de Shakespeare, quelques autres de Lewis Carroll ou de James M. Barrie seront notamment reproduites⁵. Ce travail de « numérisation » est en fait un travail laborieux, sinon de tâcheron : chacune des lettres de chaque livre sera tapée à la main, les unes après les autres. En 1990, de façon contemporaine à la jeunesse du Web, le projet prend un nouvel essor et bénéficie d'une collaboration internationale : les collections s'élèvent à environ 1000 livres en 1997 ; 4000 livres en 2001 ; et 15000 livres en 2005⁶. Entre le livre et la version numérique, il n'y a pas d'image : juste le travail de transcription manuel des caractères. C'est une numérisation des livres « en mode texte »⁷ : l'information textuelle seule, stockée sur disque dur, est reproduite sur l'écran, cela « destructurant l'objet livre »⁸. Avec cette reproduction en caractères alphanumériques, la structure physique du livre – sa mise en page – est perdue ; mais on peut en revanche rechercher un mot et retrouver un passage plus aisément.

Le texte numérique ne se définit pas seulement comme une reproduction électronique du texte imprimé, mais comme une transformation de l'information en une suite de signes codés. Concrètement, chaque caractère est représenté par une valeur numérique, selon un système de codage – ainsi tel que l'**ASCII** (American Standard Code for Information Interchange) ou, plus récemment, l'**Unicode**, qui attribue à chaque lettre, chiffre ou symbole une séquence binaire, une suite de *bits*, c'est-à-dire de 0 et de 1. Ce passage de l'écriture alphabétique à la codification binaire permet au texte d'être manipulé comme une donnée discrète : il devient possible de rechercher automatiquement un mot, de compter des occurrences, de structurer des chaînes de caractères.

Cette démarche d'encodage de l'information, qui ne concerne pas ici proprement l'historien, est exemplaire au regard des méthodes de *numérisation* des documents textuels en ce sens qu'elle traduit une forme analogique — physique ou continue — en une forme numérique,

⁵Marie Lebert, *gutemberg.org/cache/epub/27040/pg27040.txt*, URL : <https://www.gutenberg.org/cache/epub/27040/pg27040.txt> (visité le 17/08/2025).

⁶*Ibid.*

⁷Emmanuelle Bermès, *De l'écran à l'émotion : quand le numérique devient patrimoine*, Country : FR 20 cm. PSL = Université Paris sciences & lettres. Bibliogr. p. 231-234. Index., Paris, 2024, URL : 893734 (visité le 22/08/2025), 30-33.

⁸*Ibid.*

discrète. L'opération de transcription manuelle, caractère par caractère, est ici comparable à celle d'un dépouillement systématique sur archives papier : il s'agit de saisir l'information contenue dans les sources dans un dispositif tabulaire, par exemple un tableur⁹. La similarité n'est toutefois que d'ordre opératoire. Même si les enjeux intellectuels ne sont pas les mêmes, il y a un face-à-face entre un opérateur et la source à retranscrire. Il y a une reproduction qui n'est pas photographique, mais manuelle. Dans le cas de Michel Hart et du Projet Gutenberg, la répétition du texte littéraire reste relativement linéaire et vise une reproduction intégrale. À l'inverse, la transcription historique – qui n'est pas nécessairement moins laborieuse – suppose *en même temps* une enquête critique : sélectionner, structurer, et souvent synthétiser des données pour les « mettre en table », c'est-à-dire les rendre comparables, quantifiables. La transcription de sources historiques est tournée vers sa structuration, d'une « mise en fiche »¹⁰, même si celle-ci est implicite – par exemple l'ordre des éléments transcrit est une information séquentielle de cheminement de lecture. Ce schème opératoire transcriptif peut être qualifié, avec Simondon, de travail de *transduction*¹¹ : un processus par lequel l'information passe d'un support et d'un régime de signification à un autre, selon des contraintes à la fois techniques et des exigences intellectuelles. Dans le cas de la transcription numérique, l'information change de milieu technique et son inscription *in silicium* permet de reconsidérer le texte discrétisé comme un ensemble d'éléments manipulables, par exemple par des algorithmes de tri. Le texte numérique peut être alors considéré selon différents degrés de structuration : tantôt comme une « répétition linéaire » et brute des sources originales à l'instar des premières éditions du **Projet Gutenberg** ; tantôt comme une information choisie et hiérarchisée, tendue vers un raffinement structurel, comme l'implique une mise en tableau.

Dans le cas des historiens, ce passage implique un véritable travail d'individuation des données – c'est-à-dire de leur transformation au regard du contexte technique qui joue ici comme un milieu : il faut découper des flux documentaires continus en unités discrètes (noms, dates, professions, événements par exemple), qui ne préexistent pas à l'opération de transcription mais sont construites, reformulée par elle, avec la contrainte ultérieure de pouvoir retrouver l'information encodée. Des stratégies d'habillage de l'information saisie sont à envisager du même mouvement, par exemple en dotant le texte d'un « appareil critique » qui permettent un retour au texte original à travers des clés qui en indexe le contenu¹². La numérisation en mode texte est alors une opération configuratrice : la saisie manuelle se fait

⁹Claire Lemerrier et Claire Zalc, *Méthodes quantitatives pour l'historien*, ISSN : 0993-7625, 2008, DOI : 10.3917/dec.lemer.2008.01.

¹⁰bertfiche.

¹¹chatonsky.

¹²Marc Van Campenhoudt, « Une norme de dépouillement terminologique en langue française », *Equivalences*, 21-1 (1992), Publisher : Persée - Portail des revues scientifiques en SHS, p. 121-136, DOI : 10.3406/equiv.1992.1147.

l'instrument d'un changement de régime technique du support de l'information car elle implique, à différent degrés, un besoin de mise en structure. Du côté des historiens, si ce travail de transduction informationnelle, plus sophistiqué que la transcription littérale, peut être comparé au travail de terrain du sociologue ou de l'ethnographe – en ce sens qu'elle suscite justement des questions et reconfigure les valuations de l'enquête¹³¹⁴ – il s'adosse surtout à l'élaboration de nouvelles données sur les données collectées. Ces « données sur les données » – ces **métadonnées** –, nécessaires par exemple pour mettre en table l'information obtenue, relèveraient d'un *design* ou, autrement dit, d'une stratégie de composition de l'information en vue d'en produire une représentation intelligible pour un traitement ultérieur¹⁵. Ces métadonnées, plus ou moins riches ou explicites mais qui permettent de ranger les données collectées, sont propre à l'historien qui ajuste ces catégories à ses besoins. Si bien que ce processus évaluatif de mise en catégorie de l'information capturée accompagne la transcription manuelle et littérale des sources. Elle s'inscrit dans une démarche éditoriale telle que décrite par Steven DeRose, David Durand, Elli Mylonas et Allen Renear, qui se représentent le texte comme une structure hiérarchique ordonnée d'objets et de contenu¹⁶.

Le travail de saisie manuelle, avec ou sans métadonnées, n'est évidemment pas une nouveauté introduite par l'ordinateur. Bien avant l'ère numérique, les historiens s'y adonnaient déjà. Ainsi, Pierre Chaunu qui, en 1947, recopiait à la main, sur papier, les données issues des archives microfilmées et des ouvrages nécessaires à sa thèse, afin de les ordonner et de les exploiter systématiquement¹⁷ ; ou encore Ladurie sous forme de fiches ou de tableaux [Ladurie]. Au-delà du « bricolage »¹⁸ transcriptif, propre à chaque chercheur, l'histoire de la fiche érudite nous indique également des ambitions de systématisation lesquelles conduisent à une véritable ingénierie du glanage documentaire¹⁹. Citons par exemple « l'armoire érudite », les boîtes ou les casiers extensibles de l'entreprise *Borgeaud* permettant de ranger l'information dans des bonnes cases, le casier où la position dans un classeur ayant valeur ici de « métadonnée analogique »²⁰. Aujourd'hui encore, malgré l'apparition d'outils de transcription

¹³C. Lemerrier et C. Zalc, *Méthodes quantitatives pour l'historien...*

¹⁴John Dewey, *La formation des valeurs*, La Découverte, Paris, 2011.

¹⁵Anne-Lyse Renon, *Design & sciences*, fr-FR, URL : <https://www.puv-editions.fr/ouvrage/design-sciences/> (visité le 22/08/2025).

¹⁶Steven J. DeRose, David G. Durand, Elli Mylonas et Allen H. Renear, « What is text, really ? », *Journal of Computing in Higher Education*, 1–2 (déc. 1990), p. 3-26, DOI : 10.1007/BF02941632.

¹⁷Bertrand Müller, « De la formation d'un concept à l'invention d'une tradition : les avatars de l'histoire sérielle », dans *Un historien dans ses lendemains : Pierre Chaunu*, dir. Denis Crouzet et Alain Hugon, Code : Un historien dans ses lendemains : Pierre Chaunu, Caen, 2021 (Symposia), DOI : 10.4000/books.puc.15437.

¹⁸Claude Levi-Strauss, *La pensée sauvage*.

¹⁹Jean-François Bert, *Une histoire de la fiche érudite*, Code : Une histoire de la fiche érudite Publication Title : Une histoire de la fiche érudite Reporter : Une histoire de la fiche érudite Series Title : Papiers, Villeurbanne, 2017 (Papiers), URL : <https://books.openedition.org/pressesenssib/6211> (visité le 21/08/2025).

²⁰*Ibid.*

automatique [voir section 2], cette pratique demeure courante : toutes les sources ne sont pas disponibles en version numérique, et le chercheur, tout comme l'étudiant ou le généalogiste, peut être amené à relever lui-même les informations qui l'intéressent, directement en salle d'archives ou lors du dépouillement de fonds imprimés.

Le mode opératoire de la numérisation « en mode texte » constitue en ce sens un cas exemplaire, puisqu'il s'oppose radicalement à la logique de la numérisation photographique, dite « en mode image »²¹²². Il ouvre également des perspectives pour le traitement quantitatif, dans la mesure où il produit une matière directement exploitable : des données susceptibles d'être structurées — par une mise en table ou un encodage hiérarchique tel que la **TEI** — et manipulées — par exemple à travers la recherche de motifs textuels.

2. En « mode image »

À l'opposé du « mode texte », la numérisation en « mode image » repose sur la reproduction photographique des documents, cherchant à restituer leur matérialité visuelle : texte, blancs, marges, typographie, ornements, etc. Tout est fixé dans une matrice de pixels. Héritière des microfilms et des fac-similés, cette pratique connaît une expansion décisive dans les années 1990, avec l'essor du Web et le lancement des premières grandes campagnes institutionnelles de numérisation. Deux projets emblématiques illustrent cette dynamique : Gallica (BnF, 1997) et Google Books (2004)²³. Leur ambition est similaire — mettre à disposition le patrimoine imprimé à grande échelle — même si, pour Gallica, il s'agit de s'inscrire dans une mission de service public. Dans les deux cas, la numérisation institutionnelle en mode image suppose des investissements lourds en infrastructures, en personnels et en politiques documentaires²⁴. Elle se distingue ainsi des pratiques de transcription textuelle, souvent issues de gestes individuels ou collaboratifs (historien recopiant ses sources, dépouillements collectifs, corrections d'OCR par **crowdsourcing**). Certes, des chercheurs ou amateurs produisent eux aussi des photographies de documents — parfois propres, parfois très imparfaites —, mais ces fichiers, à défaut d'un soin documentaire, restent isolés, de qualité variable, sans métadonnées ni garantie de pérennité. Si bien qu'ici, photographier soi-même ses sources — par exemple aux archives — ne revient finalement qu'à remettre à plus tard le travail de dépouillement. Ce qui d'ailleurs n'empêche finalement une laborieuse transcription en mode texte mais non plus en face des sources mais de leur reproduction numérique.

Sur le plan technique, ces images sont matricielles : elles fixent l'apparence de la page

²¹E. Bermès, *De l'écran à l'émotion...*

²²*Numériser et mettre en ligne...*

²³E. Bermès, *De l'écran à l'émotion...*

²⁴*Numériser et mettre en ligne...*, p. 66-88.

mais le contenu intellectuel « littéraire » demeure opaques pour l’ordinateur. Une image numérique est un tableau – une *matrice* – d’une largeur et d’une hauteur données, comportant alors largeur \times hauteur pixels, pixels qui encode l’information colorimétrique sur trois vecteurs : le paramètre *rouge*, le paramètre *vert*, et le paramètre *bleu*. La combinaison de ces trois paramètres, selon les règles de la synthèse colorimétrique additive, permettent de restituer, pour chaque pixel, l’ensemble des couleurs du spectre visible. Qu’elles proviennent d’une campagne institutionnelle ou d’un smartphone amateur, elles ne permettent pas la recherche plein texte sans OCR ou segmentation. Dans le cas des photographies amateurs, pouvant être floues ou mal cadrées, l’OCR est même impraticable, réduisant ces fichiers à des fac-similés inertes, reportant ainsi la tâche de saisie manuelle non pas à partir des documents matériels, mais à partir de leur représentation numérique. Ce qui permet de souligner que ce n’est pas la technique de numérisation qui « fait » le mode opératoire ; mais bien le rapport de l’opérateur à un système technique plus ou moins sensible à l’information et sa capacité à la transformer²⁵.

En effet, « numériser n’est pas éditer »²⁶. Là où la mise en table implique un travail de curation plus ou moins entendu — sélection, structuration, annotation —, la capture photographique ne livre qu’une matière brute. Sans enrichissement éditorial, sans métadonnées ni transcription automatique, ces images demeurent orphelines de leur contenu textuel : de simples objets visuels, inaccessibles à toute interrogation systématique. Leur valeur scientifique dépend donc entièrement des traitements ultérieurs qui les convertissent en données exploitables. Dans le cas de la numérisation amateur, ces fichiers constituent le plus souvent un point de départ, ou une stratégie mnémonique pour différer le travail de transcription lors de l’enquête sur les sources. À l’inverse, pour la numérisation institutionnelle, ils relèvent d’une logique patrimoniale : il s’agit avant tout de restituer des ouvrages de nature variée par la reproduction photographique, solution pragmatique mais qui pose d’emblée la question de l’alternative avec le mode texte. Comme le rappelait Jean-Didier Wagneur à propos de Gallica :

« Nous avons le devoir patrimonial de restituer l’image du document tel qu’il a été déposé et le choix du mode image (fac-similé électronique) s’est imposé. Cette option a été à l’origine de nombreuses questions autour de l’alternative que le mode texte présentait. [...] On voit qu’à terme, la saisie en mode texte aurait débouché sur la nécessité de produire des documents mixtes (texte et image) afin de préserver l’intégrité de tous les documents de nature graphique

²⁵Gilbert Simodon, *Du mode d’existence des objets techniques*, Aubier, 1958.

²⁶manuefig, *Numériser ce n’est pas éditer (2)*, fr-FR, janv. 2005, URL : <https://figoblog.org/2005/01/18/519/> (visité le 20/08/2025).

(illustrations, cartes, reproductions, graphes et expériences scientifiques) figurant dans les ouvrages numérisés. »²⁷

Se dessine une tension durable entre deux régimes de numérisation : d'un côté, la transcription textuelle qui repose sur la couteuse « nécessité de faire saisir les œuvres de plusieurs centaines, voire milliers, d'auteurs » exigeant un « accompagnement scientifique considérable »²⁸ ; de l'autre, la reproduction visuelle, portée par des politiques institutionnelles, qui fabrique des corpus massifs mais souvent réduits à l'état de matière brute.

3. La « datafication »

Cette opposition doit enfin être replacée dans l'horizon plus large de la *datafication*²⁹. La *datafication* est le processus qui vise à quantifier un phénomène de sorte qu'il soit calculable et analysable³⁰. Elle est en quelque sorte un « schème opératoire »³¹ permettant la calculabilité des sources avec un outillage informatique. Cette mise en données « insiste sur la notion de processus » et « se définit par les choix opérés par les organismes qui y procèdent », cela impliquant « les critères d'inclusion [de] corpus à numériser » ; l'élaboration de métadonnées descriptives situées, lesquelles ont un impact sur leur découvrabilité puisque les moteurs de recherche s'y appuient³².

Si bien que numériser, ce n'est pas seulement reproduire. C'est transformer des artefacts en données, dans un cadre technique, social et institutionnel qui oriente les usages, fixe les normes de conservation et conditionne l'accès même aux sources. Elle met en évidence deux conceptions distinctes de la numérisation : d'un côté, la transcription textuelle, qui construit les données par un travail de sélection et est tendue vers une structuration plus ou moins affirmée ; de l'autre, la reproduction visuelle, qui se limite à conserver une représentation plane de la matérialité de l'objet. L'histoire des pratiques documentaires de « mise en données » témoigne de cette tension durable entre deux paradigmes concurrents³³ qui sont alors autant techniques qu'institutionnels. En suivant Bruno Latour, on peut dire que « nous ne devrions jamais parler de 'données', mais toujours d'obtenues' »³⁴. La saisie manuelle n'est pas une

²⁷Jean-Didier Wagneur, « Gallica : la bibliothèque électronique de la BnF : quel accès pour les personnes handicapées visuelles ? », dans *Bibliothèques et publics handicapés visuels*, Code : Bibliothèques et publics handicapés visuels, Paris, 2002 (Paroles en réseau), DOI : 10.4000/books.bibpompidou.1500.

²⁸*Ibid.*

²⁹F. Clavert, « Une histoire par les données?... ».

³⁰*Ibid.*

³¹G. Simodon, *Du mode d'existence des objets techniques...*, p. 236.

³²F. Clavert, « Une histoire par les données?... », p. 123.

³³E. Bermès, *De l'écran à l'émotion...*, p. 29.

³⁴Jérôme Denis et Samuel Goëta, « Les facettes de l'Open Data : émergence, fondements et travail en coulisses », dans *Big data et traçabilité numérique : Les sciences sociales face à la quantification massive*

simple transplantation de contenu, mais une construction — un fait mobilisable conditionné par des choix de catégorisation, de format, et d’usage. La reproduction photographique, à l’inverse, ne produit pas directement de données exploitables, mais fige l’apparence visuelle du document, laissant le texte dans un état opaque tant qu’aucune opération d’extraction ou d’annotation n’est réalisée.

Chaque « mise en données » est ainsi moins une instanciation pure de la source dans le giron du binaire qu’une stratégie épistémique de sa présentation au sein d’un réseau socio-technique instituant³⁵. Dans cette perspective, on peut dire avec Cornelius Castoriadis que la numérisation est un geste « instituant » : elle crée de nouvelles manières de faire exister et de rendre visibles les sources, conditionnant les régimes d’intelligibilité qui en découlent³⁶. Or, au sein des politiques contemporaines de numérisation, cette dimension instituante prend une forme discursive et normative particulière : celle du *patrimonial*. Le patrimoine est un « passé-présent » sans cesse réinterprété, qui puise dans l’imaginaire institué et reforme en retour de nouvelles significations. La numérisation est justifiée et orientée par un vocabulaire de démocratisation et de valorisation, dans une fibre tout encyclopédique, tel que défendu par Jean-Didier Wagneur cité précédemment. Autrement dit, ce qui est numérisé n’est pas seulement conservé ou reproduit : il est institué comme patrimoine, doté d’une valeur « émotionnelle » et sociale spécifique³⁷. Les données produites par la numérisation sont donc indissociables d’une politique culturelle qui configure les conditions d’accès, de visibilité et de réutilisation des corpus, ce qui implique nécessairement des biais de sélection ou tout simplement des priorités déterminées par les politiques de conservation de documents fragiles.

4. Pratiques historiennes : sphère technique, sphère sociale

La datafication ne consiste donc pas seulement en un enchaînement d’opérations techniques — OCR, structuration, encodage —, mais en un processus situé, au croisement de la sphère technique et de la sphère sociale. Il n’existe pas de « données brutes » : toute donnée est déjà une *capta*, c’est-à-dire une information « prise », construite dans et par un cadre interprétatif qui reflète des choix méthodologiques et institutionnels³⁸. Leur mise à disposition est elle-même également une affaire de visualisation : la mise en ordre des résultats d’une

des individus, dir. Pierre-Michel Menger et Simon Paye, Code : Big data et traçabilité numérique : Les sciences sociales face à la quantification massive des individus, Paris, 2017 (Conférences), p. 121-138, DOI : 10.4000/books.cdf.5005.

³⁵A.L. Renon, *Design & sciences...*

³⁶Michel Rautenberg, « Les chemins croisés du patrimoine et de l’imaginaire », dans *L’imaginaire patrimonial : Figures de l’urbanité contemporaine*, Code : L’imaginaire patrimonial : Figures de l’urbanité contemporaine, Rennes, 2024 (Essais), p. 13-52, DOI : 10.4000/13ipp.

³⁷E. Bermès, *De l’écran à l’émotion...*

³⁸Johanna Drucker, *Visualisation. L’interprétation modélisante*, B42, Paris, 2020.

recherche en ligne appartient au giron de la visualisation des données – et comme on l’a sous entendu précédemment, les stratégies épistémiques de représentation de connaissance est une affaire de *design*. D’ailleurs certains artistes comme le duo Vasulka, dans la même veine du concept de *graphesis* de Johanna Drucker³⁹ parlent volontiers de « nouvel espace épistémique », « d’épistémè numérique »⁴⁰ ou encore « d’image relation »⁴¹, ce dernier concept insistant plutôt sur la notion d’interactivité. Pour ces artistes, il est question de faire grincer la dimension interprétative et graphique de l’accès à l’information à travers des interfaces car, si l’habitude peut nous conduire à considérer la présentation des données par des moteurs de recherche comme « objectifs », il faut au contraire montrer qu’il s’agit de dispositifs techniques partiels, construits historiquement⁴². S’il peut bien y avoir une prétention encyclopédique dans les dispositifs techniques d’accès aux sources⁴³, il y a également une dimension esthétique, « jouable », qui est une condition à la lisibilité du dispositif numérique⁴⁴. Dès lors, il faut considérer les données et les métadonnées à la lumière de leur présentation, présentation qui doit faire l’objet de décisions, de stratégies au regard de ce qui importe de montrer ou de cacher – bref : il y a là des *valuations* dans la médialité, en reprenant ce mot dans son sens deweyien⁴⁵, c’est-à-dire une dépendance des schèmes techniques opératoires aux processus de formation des valeurs. Les institutions patrimoniales sont des acteurs exemplaires de cette double dépendance des dispositifs techniques aux attentes sociales ou scientifiques. Un exemple particulièrement riche de ces réflexions se trouve dans le PLAO (pour « Poste de Lecture Assistée par Ordinateur ») imaginé à la BnF dans les années 1990 sous l’impulsion de Bernard Stiegler. Il s’agissait d’une interface destinée à incarner le lecteur « savant » au cœur d’un dispositif instrumenté, permettant non seulement de consulter des textes numérisés, mais aussi de les annoter, de structurer dynamiquement un corpus, de naviguer, d’archiver, de copier ou d’indexer en temps réel. Le PLAO n’est jamais devenu un équipement déployé à large échelle, mais il s’est imposé comme un « objet-frontière » — au sens de Star et Griesemer — structurant une coalition entre informaticiens, philosophes, historiens et bibliothécaires, engagés dans la conceptualisation d’un nouvel usage de la bibliothèque numérique⁴⁶.

³⁹ *Ibid.*

⁴⁰ Jean-Marie Dallet et Bertrand Gervais (éd.), *Architectures de mémoire*, Code : Architectures de mémoire Publication Title : Architectures de mémoire Reporter : Architectures de mémoire Series Title : La Grande Collection ArTeC, Nanterre, 2019 (La Grande Collection ArTeC), URL : <https://books.openedition.org/pupo/25762> (visité le 20/08/2025).

⁴¹ Jean-Louis Boissier, *La relation comme forme*, Les Presses du Réel, Dijon, 2009.

⁴² Lorraine Daston et Peter Galison, *Objectivité*, Les Presses du Réel, Dijon, 2012.

⁴³ J.D. Wagneur, « Gallica... ».

⁴⁴ J.L. Boissier, *La relation comme forme...*

⁴⁵ J. Dewey, *La formation des valeurs...*

⁴⁶ Gaëlle Béquet, « La bibliothèque numérique à la Bibliothèque de France : de l’objet-valise à l’objet-frontière (1988-1993) », dans *Trois bibliothèques européennes face à Google : Aux origines de la bibliothèque numérique (1990-2010)*, Code : Trois bibliothèques européennes face à Google : Aux origines de la bibliothèque

Ces interrogations contemporaines ne surgissent pas *ex-nihilo* : elles prolongent une histoire plus ancienne des rapports entre historiens et outils informatiques. Ces transformations récentes s'inscrivent dans une histoire plus longue des usages de l'informatique par les historiens. Dès les années 1950, des expériences pionnières lient mécanographie et analyse sérielle⁴⁷, dans la lignée des « archives quantitatives » chères à l'école des *Annales*. Dans les décennies 1960–1970 voient s'imposer l'ambition d'une histoire totale⁴⁸. La prophétie de Le Roy Ladurie — « l'historien de demain sera programmeur ou ne sera pas » — illustre cet horizon, même si les limites de l'histoire sérielle conduisent rapidement à relativiser l'objectivité promise par la machine. Dans les années 1980–1990, l'apparition du micro-ordinateur personnel, puis des premières bases de données relationnelles et de revues comme *Le Médieviste et l'Ordinateur*, favorise une technicisation diffuse des pratiques, souvent portée par des chercheurs passionnés plutôt que par une politique disciplinaire globale⁴⁹. Le Web, à partir de la fin des années 1990, change l'échelle de ces usages : il facilite l'accès et la diffusion des corpus (Gallica, revues.org) et transforme le rapport aux archives grâce aux appareils photo numériques et aux interfaces de recherche. L'émergence des humanités numériques dans les années 2000 fait de ces pratiques dispersées un champ identifié, mais aussi un espace de tensions : entre injonctions institutionnelles, résistances disciplinaires et négociations interdisciplinaires. L'histoire des pratiques historiennes « numériques » apparaît ainsi comme un processus long, fait d'allers-retours entre engouements, critiques et réinventions, qui relativise l'idée d'un tournant soudain pour insister sur la continuité d'une adaptation progressive des historiens à leurs outils.

Avec l'essor du Web, la datafication ne se réduit plus à un geste de transcription ou à un choix institutionnel de numérisation : elle s'inscrit dans des infrastructures réticulaires qui conditionnent la circulation et l'usage des corpus. Les documents ne sont pas seulement mis en ligne ; ils sont exposés à travers des protocoles techniques — comme les API — qui déterminent la granularité d'accès, la possibilité de réutilisation et la manière dont les sources sont découvertes. Comme le montre l'exemple du *Goût de l'archive à l'ère numérique* et de sa réflexion sur le « goût de l'API »⁵⁰, l'archive numérisée devient un objet relationnel :

numérique (1990-2010), Paris, 2015 (Mémoires et documents de l'École des chartes), p. 51-85, DOI : 10.4000/books.enc.14133.

⁴⁷Adeline Daumard et François Furet, « Méthodes de l'Histoire sociale : les Archives notariales et la Mécanographie », *Annales*, 14-4 (1959), Company : Persée - Portail des revues scientifiques en SHS Distributeur : Persée - Portail des revues scientifiques en SHS Institution : Persée - Portail des revues scientifiques en SHS Label : Persée - Portail des revues scientifiques en SHS Publisher : EHESS, p. 676-693, DOI : 10.3406/ahess.1959.2865.

⁴⁸Sébastien Poublanc et Nicolas Marqué, « Introduction au dossier « Historien · nes et numérique : pratiques et expériences vécues » », *Les Cahiers de Framespa. e-STORIA*–42 (juill. 2023), Publisher : UMR 5136 – FRAMESPA, DOI : 10.4000/framespa.14370.

⁴⁹*Ibid.*

⁵⁰F. Clavert, *Le goût de l'API / Le goût de l'archive à l'ère numérique*, fr-FR, URL : <https://gout->

elle n'existe pleinement qu'à travers les réseaux qui l'indexent, la connectent et la rendent interopérable avec d'autres ensembles de données. Cette dimension réticulaire transforme profondément la sphère sociale des archives : les corpus ne sont plus simplement conservés et transmis, mais distribués, exposés, parfois fragmentés, selon des logiques de plateformes et de moteurs de recherche. La découvrabilité des sources dépend ainsi de ces dispositifs techniques saisis dans des processus de concrétisation [Simondon], qui agissent comme de nouveaux médiateurs documentaires et configurent, en amont, les conditions de possibilité de l'enquête historique.

Autrement dit, ce que fait la numérisation aux corpus, c'est moins de les rendre « disponibles » que de les reconfigurer : par la sélection de ce qui est numérisé (et de ce qui ne l'est pas), par les formats qui conditionnent l'usage (XML-TEI, bases relationnelles, IIIF), et par les réseaux de diffusion (catalogues, moteurs de recherche, portails institutionnels) qui hiérarchisent leur visibilité. La donnée numérique n'est donc pas un miroir fidèle des sources, mais une construction sociotechnique qui oriente leur appropriation. De ce point de vue, la datafication prolonge les silences de l'archive autant qu'elle ouvre de nouvelles potentialités. Elle produit un double effet : d'un côté, elle consolide des corpus institués par les politiques patrimoniales et documentaires ; de l'autre, elle institue de nouveaux régimes de visibilité et de calcul, rendant possible des analyses sérielles, des croisements de données ou des visualisations inédites. C'est dans cette tension que se joue aujourd'hui la confiance des chercheurs dans les « données » numériques : non comme transparence des sources, mais comme résultat de choix techniques et sociaux qu'il convient de rendre visibles et discutables. La datafication amplifie ainsi certains silences archivistiques : ce qui n'a pas été consigné, ou ce qui est difficile à transcrire automatiquement, reste hors champ.

Enfin, la datafication est aussi un processus social : elle reflète et prolonge les hiérarchies documentaires héritées. Les corpus numérisés surreprésentent souvent les groupes dominants (élites, institutions, employeurs), au détriment des voix minoritaires. Le danger est alors de tomber dans une réification de la disponibilité où l'historien travaille sur ce qui est disponible, non sur ce qui est historiquement pertinent ou accessible. La question devient dès lors : comment documenter ces biais et construire la confiance dans des données issues de systèmes techniques ?

Chapitre 4

En passant par le texte : de l'image à la donnée structurée

Le choix institutionnel de la BnF, à travers *Gallica*, de numériser massivement les corpus patrimoniaux en mode image s'inscrit dans une logique de valorisation d'une trace visuelle de l'objet imprimé, indépendamment des évolutions des standards textuels ou des logiciels de lecture. L'image numérique, photographique, motive une certaine expressivité, laquelle est lacuneuse du côté du texte brut. La typographie d'un ouvrage peut parler ; les cartes, dessins et schéma ne sont pas laissés par l'option de cette numérisation photographique. Mais cette stratégie, qui assure une intelligibilité visuelle de la source, laisse son contenu informationnel dans un état opaque pour la machine. C'est précisément pour franchir cette opacité et rendre ces corpus interrogeables en plein texte qu'intervient l'OCR (*Optical Character Recognition*), technologie pivot entre la reproduction visuelle et la transformation en données exploitables. Dans ce chapitre, nous reviendrons sur les aspects techniques de l'OCR qui viennent donner à l'image un double textuel, plus prolixe qu'une matrice de pixels.

I. La reconnaissance optique de caractères

1. Une vue d'ensemble

La reconnaissance optique de caractères — que l'on désignera désormais sous l'acronyme OCR — désigne l'ensemble des procédés permettant d'extraire automatiquement du texte lisible par machine à partir d'images numérisées. Historiquement, le terme s'applique aux documents imprimés composés avec des caractères typographiques, tandis que l'on réserve plutôt celui de *Handwritten Text Recognition* (HTR) aux documents manuscrits, qui présentent des difficultés spécifiques liées à la variabilité de l'écriture humaine et à l'absence

de régularité formelle des lettres. Dans ce qui suit, nous laisserons cet aspect de côté pour nous concentrer sur l'OCR *stricto sensu*.

L'OCR constitue l'opération clef qui rend un document scanné ou photographié interrogeable en plein texte. Sur le plan technique, il s'agit de transformer une matrice de pixels — pouvant être en noir et blanc, en niveaux de gris ou en couleur RVB (rouge, vert, bleu) — en une séquence discrète de symboles alphabétiques. L'unité et l'intégrité des trains d'information binaire étant une prérogative des formats et des algorithmes de compression. Ces couleurs peuvent avoir différents niveaux de finesse : un encodage de la couleur sur un seul bit (1 ou 0), ne laisse que deux possibilités, à l'instar de images bitmap (par exemple, les numérisation de microfilms sur Gallica). Une image RVB, encodée sur 1 octet par canal (soit 8 bits par canal ou 24 bits au total), permet de restituer une gamme plus large de couleurs, avec $(2^8)^3$ possibilités, soit plus de 16 millions de couleurs. Une image en nuance de gris encodée sur un seul octet restitue une gamme de 256 valeurs. Une image RVB d'une profondeur de 8 bits de $h \times l$ contient alors au minimum $h \times l \times 24$ bits d'information, sans compter le processus de compression qui permet de résumer l'information. La quantité d'information est importante : plus elle est haute, plus la réalité continue est échantillonnée – donc la photographie du document est plus fidèle – mais elle devient plus lourde et donc couteuse en calcul. Par là, on voit que, du point de vue de l'ordinateur, un caractère n'existe pas comme « lettre » mais comme la traduction visuelle d'une matrice d'informations. La lettre, donc les mots et les phrases, sont comme des agencement de points lumineux dans un espace matriciel – ou plus précisément tensoriel dans le cas des images RVB car chaque pixel est en fait un vecteur en trois dimensions. Certes, un caractère encodé en **Unicode** ou en **ASCII** est également un train binaire. En revanche son décodage découle immédiatement sur une information explicite (un nombre faisant référence à une lettre : par exemple « A », « B » et « C » valent respectivement 65, 66, 67 en ASCII, lesquels valent également 01000001, 01000010 et 01000011 en binaire). Cela n'est pas le cas pour la couleur qui doit être de nouveau interprétée. Un « l » noir placé au milieu d'une page blanche, par exemple, est graphiquement un ensemble de pixels plus ou moins noirs connexes ; mais du point de vue d'une matrice, elle n'est pas vraiment une série de valeurs qui se suivent car il faut parcourir l'ensemble des valeurs pour détecter cette connexité – et cela sans parler bien entendu du bruit pouvant « couper » les ponts entre les pixels. On remarque au passage la difficulté de détecter la ponctuation, où les caractères qui n'ont graphiquement pas de connexité, comme la lettre « i » ou le point d'exclamation¹. Il y a donc ambiguïté entre l'information matricielle et sa référence. Si tous les algorithmes de détection de caractères n'emploient pas des algorithmes de connexité comme il vient d'être

¹R.G. Casey et E. Lecolinet, « A survey of methods and strategies in character segmentation », *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 18-7 (juill. 1996), p. 690-706, DOI : 10.1109/34.506792.

vulgarisé, les processus d’OCRisation sont en général sujets aux erreurs² et l’on comprend dès lors pourquoi, jusqu’aux années 1990, des initiatives pionnières comme le *projet Gutenberg* préféraient la saisie manuelle du texte³. Aujourd’hui, les documents imprimés en caractères d’imprimerie affichent des scores assez hauts – ce qui n’est d’ailleurs pas le cas des moteurs d’HTR⁴.

La chaîne de traitement qui mène d’une image brute à un texte exploitable peut se décrire en plusieurs volets, si on s’autorise d’abord quelques généralités qu’il conviendra de modérer ensuite. Cette chaîne de traitement, donc, commence par une phase d’acquisition et de normalisation. L’acquisition, c’est l’étape de la prise de vue – on ne prend ici en considération que les documents qui ne sont pas nativement numériques. La qualité de la reconnaissance dépend en effet fortement de l’image initiale : une page légèrement inclinée, gondolée ou affectée par du bruit (comme c’est souvent le cas avec des microfilms granuleux) entraîne une baisse sensible de performance. Pour y remédier, on peut procéder à des corrections géométriques, comme le redressement (*deskew*) ou la compensation des courbures de page (*dewarp*), à un équilibrage des contrastes ou encore à un débruitage. Ces pré-traitements permettent d’optimiser les conditions de reconnaissance mais ne sont pas neutres : appliqués trop agressivement, ils peuvent détruire une partie de l’information utile. C’est la raison pour laquelle, à grande échelle, l’idéal reste une numérisation soignée en amont, qui évite de surcharger une chaîne de traitement déjà coûteuse.

Vient ensuite l’étape de segmentation, où le système doit identifier les unités pertinentes à traiter, de la mise en page aux caractères eux-mêmes – les « glyphes ». Les approches les plus anciennes reposaient sur des heuristiques « simples », telles que la connexité des pixels pour reconnaître des zones d’intérêt à étudier⁵. Les systèmes récents recourent désormais à des méthodes d’apprentissage profond capables de segmenter automatiquement les documents. Mais segmenter ne suffit pas : il faut encore mettre en ordre les unités visuelles pour qu’elles deviennent une suite lisible. C’est l’étape de sérialisation, où une ligne d’image est convertie en séquence de caractères. Les approches anciennes procédaient caractère par caractère⁶, tandis que les modèles neuronaux modernes lisent directement la ligne entière comme un flux d’information, puis produisent une suite de lettres alignées⁷.

²Guillaume Chiron, Jean-Philippe Moreux, Antoine Doucet, Mickaël Coustaty et Muriel Visani, « Erreurs OCR et biais d’indexation : impact sur les usages », dans *17ème conférence Extraction et Gestion des Connaissances, Atelier Journalisme Computationnel*, Grenoble, France, 2017, p. 69-73, URL : <https://hal.science/hal-01455763> (visité le 22/08/2025).

³E. Bermès, *De l’écran à l’émotion...*

⁴G. Chiron, J.P. Moreux, A. Doucet, *et al.*, « Erreurs OCR et biais d’indexation... ».

⁵R. Casey et E. Lecolinet, « A survey of methods and strategies in character segmentation »...

⁶*Ibid.*

⁷Alex Graves, Santiago Fernandez, Faustino Gomez et Jurgen Schmidhuber, « Connectionist Temporal Classification : Labelling Unsegmented Sequence Data with Recurrent Neural Networks » ().

La question de la binarisation – la « mise en noir et blanc » des images – illustre d'ailleurs bien l'évolution des méthodes. Jusqu'au début des années 2000, la première étape consistait donc à transformer une image en noir et blanc⁸, notamment pour faciliter la détection de pixels connexes. Pour simplifier : ce qui était noir était de l'encre ; ce qui était blanc du papier. Cette simplification rendait plus facile la détection des lettres par les machines, qui pouvaient alors comparer directement des formes typographiques pré-enregistrées. Mais ce passage forcé au noir et blanc avait un coût : perte d'information sur les nuances, et sensibilité accrue aux défauts d'impression ou aux images bruitées. De même, il n'existe pas d'opération de seuillage universelle. On peut appliquer effectivement un seuil uniforme sur l'image, ou bien effectuer des moyennes locales en faisant glisser une petite matrice – ce sont des méthodes « convolutives », à l'instar du filtre gaussien ou une simple moyenne locale [Daniel Shiffman, @seuillage]. Le choix de la manière de binariser dépend de la qualité de la prise de vue, par exemple de l'uniformité de la lumière sur les pages, laquelle d'ailleurs est difficile à obtenir dans le cas de la prise de vue amateur. Aujourd'hui, cette étape n'est plus incontournable. Elle reste pratique pour traiter des documents très dégradés — comme certains microfilms — mais les systèmes modernes savent travailler directement avec des images en niveaux de gris ou même en couleur. Certains réseaux apprennent automatiquement à « décider » quels contrastes ou seuils sont pertinents, là où les anciennes méthodes appliquaient une règle fixe.




FIG. 4.1 : OfBook

On comprend ici la bascule entre deux époques de l'OCR. Les anciens systèmes fonctionnaient comme une chaîne d'opérations séparées : on nettoyait l'image, on la binarisait, on comparait chaque forme à une base de motifs connus, puis on s'aidait de dictionnaires

⁸*Ibid.*

pour corriger les erreurs. C’était une sorte de mécanique en plusieurs rouages, où chaque étape pouvait accumuler des approximations. L’OCR, par exemple aux débuts de *Tesseract*, supposait un document déjà segmenté, ce qui impliquait d’appliquer les traitements sur des entrées standardisées⁹. Les systèmes contemporains, eux, reposent sur des modèles neuro-naux capables d’apprendre l’ensemble du processus de bout en bout : ils prennent une image brute et produisent directement du texte, en intégrant en interne ce qui relevait autrefois de plusieurs étapes distinctes. Cette évolution repose notamment sur les **LSTM** (*Long Short-Term Memory*), des réseaux dits « récurrents » capables de lire une ligne comme une suite d’images et d’en mémoriser le contexte pour prédire la séquence de caractères. Là où un moteur classique devait isoler chaque glyphe pour le comparer à un modèle, un LSTM fonctionne un peu comme un lecteur humain : il garde en mémoire ce qui précède pour interpréter les lettres suivantes, même quand elles sont collées ou abîmées. Ces architectures ne sont évidemment pas infaillibles, mais elles illustrent de manière exemplaire ce que Simondon appelait la *concrétisation technique*¹⁰ : les différentes fonctions du système — nettoyage, segmentation, reconnaissance, correction — deviennent moins séparables et tendent à se fondre dans un dispositif intégré, plus cohérent mais aussi plus opaque. D’un côté, alors, avec le vocabulaire de Gilbert Simondon, on peut dire qu’il y a les dispositifs « abstraits » des méthodes d’OCR ; de l’autre, plus modernes, les dispositifs « concrets »¹¹ ou en voie de concrétisation.

Le schème opératoire « abstrait » – en « rouages » – de la reconnaissance optique des caractères, est décrite dans la littérature des années 1990–2000 comme une architecture en pipeline, où chaque étape de la reconnaissance correspondait à un module distinct : prétraitement, binarisation, segmentation des caractères, classification, puis correction linguistique¹². Dans le cas de *Tesseract* tel que présenté par Ray Smith, le moteur se contentait de prendre en entrée une image déjà binarisée et supposée contenir une seule colonne de texte¹³. La reconnaissance procédait alors par extraction des composants connectés, regroupés en glyphes, ensuite soumis à un classifieur géométrique, avant qu’une passe linguistique rudimentaire ne privilégie certaines hypothèses sur la base de dictionnaires ou de listes de fréquences¹⁴. Chaque maillon du pipeline pouvait introduire des erreurs, et une approximation en amont

⁹R. Smith, « An Overview of the Tesseract OCR Engine », dans *Ninth International Conference on Document Analysis and Recognition (ICDAR 2007) Vol 2*, ISSN : 1520-5363, Curitiba, Parana, Brazil, 2007, p. 629-633, DOI : 10.1109/ICDAR.2007.4376991.

¹⁰G. Simondon, *Du mode d’existence des objets techniques*...

¹¹Vincent Bontems, « Sur la classification des objets techniques selon Simondon », *Artefact. Techniques, histoire et sciences humaines*–3 (mars 2016), ISBN : 9782271087539 Number : 3 Publisher : Presses universitaires du Midi, p. 183-198, DOI : 10.4000/artefact.8270.

¹²R. Casey et E. Lecolinet, « A survey of methods and strategies in character segmentation »...

¹³R. Smith, « An Overview of the Tesseract OCR Engine »...

¹⁴Ray W. Smith, « History of the Tesseract OCR engine : what worked and what didn’t », dans ADS Bibcode : 2013SPIE.8658E..02S, 2013, t. 8658, p. 865802, DOI : 10.1117/12.2010051.

— par exemple une mauvaise binarisation ou une segmentation ratée — se répercutait mécaniquement sur l'ensemble de la chaîne. C'est cette architecture séquentielle, héritée des contraintes matérielles et logicielles de l'époque, que les approches contemporaines cherchent à dépasser en privilégiant des modèles neuronaux capables d'apprendre conjointement plusieurs étapes de traitement. Le tournant marqué en 2018 par l'adoption des réseaux LSTM, qui permettent de traiter une ligne d'image comme une séquence continue de signes, a ouvert la voie à une reconnaissance « end-to-end », de l'image brute jusqu'au texte¹⁵. Mais il serait trompeur de croire que cette évolution a entièrement effacé la logique du *pipeline*. Dans la pratique, même les systèmes modernes conservent une structuration en étapes : prétraitement et normalisation des images, segmentation des zones et des lignes, reconnaissance séquentielle avec LSTM ou Transformers, puis décodage et structuration des données – par exemple avec un export en ALTO/XML – intégration d'un modèle de langue. Les différences résident moins dans l'existence d'un pipeline que dans son degré d'intégration : là où chaque étape était autrefois codée manuellement, elle est désormais en grande partie apprise ou ajustée automatiquement par le modèle¹⁶. Autrement dit, la chaîne ne disparaît pas, mais elle devient plus compacte, moins visible et plus adaptable, ce qui explique à la fois les gains de performance et la difficulté accrue à contrôler ou interpréter chaque rouage.

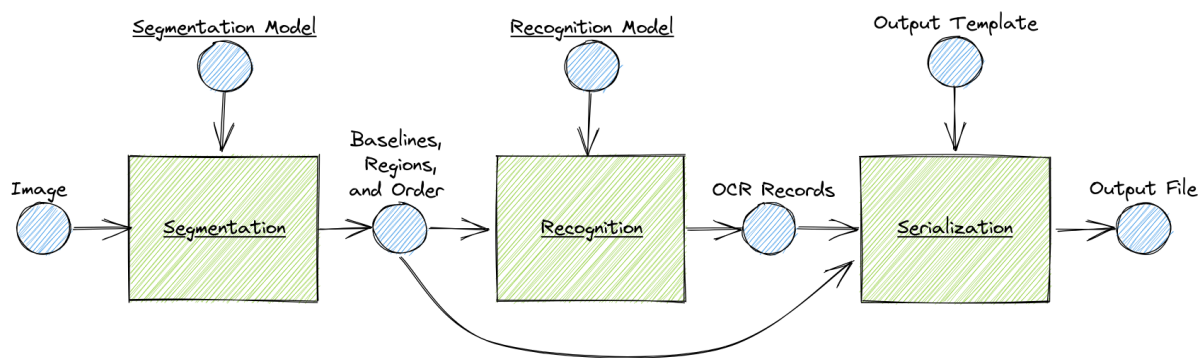


FIG. 4.2 :

A noter très récemment une nouvelle évolution des pratiques de transcription automatique avec *Mistral OCR*, présentée en 2025 par *Mistral AI*¹⁷. Contrairement aux OCR classiques centrés sur le texte seul, ce modèle est multimodal – c'est-à-dire qu'il comprend

¹⁵R. Smith, « An Overview of the Tesseract OCR Engine »...

¹⁶**pipeline-kraken.**

¹⁷*Mistral OCR / Mistral AI*, en, URL : <https://urlr.me/Cqyt9c> (visité le 21/08/2025).

simultanément le texte, les images, les tableaux, voire les équations, les assemblages textuels et visuels d'un document, et cela tout en préservant la mise en page et la hiérarchie informationnelle. Il produit une sortie structurée — notamment en Markdown ou JSON —, intercalant texte extrait et formes visuelles (images ou équations), avec préservation de l'ordre des éléments, des titres, des tableaux.

2. Les grandes technologies d'OCR

Historiquement, les premiers systèmes d'OCR, développés entre les années 1970 et 1990, étaient conçus pour reconnaître des caractères bien standardisés, tirés d'impressions propres ou de typographies contemporaines. Ils se montraient performants tant que les documents étaient homogènes et en bon état, mais trouvaient rapidement leurs limites face à la diversité des fonds patrimoniaux : imprimés anciens, journaux abîmés, écritures non latines ou manuscrits. C'est cette hétérogénéité croissante qui a conduit au développement de solutions spécialisées, plus flexibles et adaptées aux besoins des bibliothèques et des chercheurs.

Parmi ces moteurs, *Tesseract* occupe une place singulière. Développé initialement par Hewlett-Packard dans les années 1980 puis repris par Google, il est devenu l'un des logiciels libres d'OCR les plus diffusés au monde, car utilisé notamment dans de grandes bibliothèques numériques comme *Google Books* et publié en *open-source* en 2005¹⁸. Sa quatrième version, publiée en 2018, a marqué une étape importante en intégrant des réseaux de neurones récurrents – les LSTM dont on a brièvement parlé précédemment – ce qui a permis d'améliorer considérablement ses performances sur des typographies variées. Néanmoins, *Tesseract* reste relativement rigide dès lors qu'il s'agit de traiter des documents abîmés ou des écritures complexes, à l'instar de la typographie vernaculaire ou des écritures manuscrites.

À côté de *Tesseract*, citons le logiciel propriétaire *ABBYY FineReader* au coût élevé et au développement fermé limitant les possibilités de personnalisation. Bien que *Tesseract* soit devenu un standard libre et largement utilisé pour l'OCR typographique, il n'était pas assez flexible pour répondre aux défis spécifiques des corpus patrimoniaux. C'est dans ce cadre que *Kraken* a vu le jour. Conçu dès l'origine pour pouvoir être entraîné sur des corpus particuliers — imprimés anciens, écritures non latines, manuscrits, gazettes, etc. Benjamin Kiessling, dans *Kraken – a Universal Text Recognizer for the Humanities*¹⁹ décrit comment *Kraken* élimine les « implicit assumptions on content and layout » propres aux systèmes classiques, tout en permettant l'entraînement d'architectures sur mesure, la reconnaissance de scripts non standards et l'export en formats interopérables tels que PAGE XML ou ALTO

¹⁸Id., « An Overview of the Tesseract OCR Engine »...

¹⁹Benjamin Kiessling, « Kraken - A Universal Text Recognizer for the Humanities », dans *Digital Humanities 2019*, Utrecht, Netherlands, 2019, DOI : 10.34894/Z9G2EX.

XML.

Dans le prolongement de ces initiatives, la plateforme eScriptorium, développée à l'École pratique des hautes études (EPHE/PSL) au sein du projet Huma-Num, combine différents modules de segmentation et de reconnaissance. Elle intègre notamment Pero OCR pour la détection des zones et la segmentation des lignes, et Kraken pour la transcription. eScriptorium offre en outre une interface collaborative qui permet à des équipes de chercheurs, mais aussi à des communautés élargies, d'annoter, d'entraîner et de partager des modèles. Cette dimension participative en fait un outil particulièrement adapté aux humanités numériques, où la correction et l'amélioration collective des résultats constituent un enjeu central.

3. CER, WER : métriques pour évaluer la qualité de l'OCR

Dans ce contexte, la question de l'évaluation des performances devient cruciale. Si la reconnaissance automatique produit un texte exploitable, il est nécessaire de mesurer la qualité de cette transcription afin d'orienter les corrections, de comparer les moteurs ou de juger de l'efficacité d'un entraînement. Deux indicateurs dominent aujourd'hui dans le champ : le **CER** (*Character Error Rate*) et le **WER** (*Word Error Rate*).

Le **CER** mesure le pourcentage d'erreurs au niveau des caractères. Concrètement, il s'agit de comparer la sortie d'un moteur à une transcription de référence (*ground truth* ou « vérité terrain »), puis de calculer le nombre minimal d'opérations nécessaires pour transformer l'un en l'autre : substitutions, insertions ou suppressions. Formellement, ce calcul repose sur la distance de Levenshtein, un algorithme de comparaison de chaînes. Le CER s'exprime comme le rapport entre le nombre d'opérations et le nombre total de caractères de la référence. Ainsi, un CER de 5 % signifie que sur cent caractères transcrits, cinq nécessitent correction.

Le **WER**, de son côté, transpose le même principe au niveau des mots. Il se révèle souvent plus parlant pour l'utilisateur final, car une seule erreur de caractère peut parfois changer entièrement un mot (« loi » devenu « foi »). Mais il est aussi plus sensible aux fautes d'espacement ou de segmentation, ce qui en limite parfois l'usage sur des corpus anciens où les règles typographiques varient fortement.

Dans la pratique, les projets combinent souvent ces deux indicateurs [David Fleischhacker]. Le CER est préféré pour comparer des modèles entre eux, car il est plus fin et moins dépendant des conventions d'espacement, tandis que le WER donne une estimation plus intuitive de la lisibilité globale d'un texte. Dans des corpus patrimoniaux difficiles (imprimés du XIX^e siècle, microfilms, manuscrits), atteindre un CER inférieur à 5 % est déjà considéré comme un excellent résultat.

Cependant, il faut rester critique au regard de ces métriques. Comme le montre Neu-

Neudecker[Neudecker], même les mesures dites « standardisées » – que sont le CER et le WER – ne sont pas directement comparables d'un outil d'évaluation à l'autre. Une source d'écart importante réside dans le calcul des alignements, c'est-à-dire la manière dont on fait correspondre, pas à pas, la transcription automatique produite par la machine et la transcription de référence. Selon l'algorithme d'alignement retenu, par exemple un alignement global de type Levenshtein ou un alignement local optimisé, une même séquence de sorties peut être jugée plus ou moins « erronée ». Cela produit des variations sensibles du CER/WER, surtout dans les cas où l'OCR omet des caractères, inverse des espaces ou fusionne des mots. Dans les humanités numériques, un cas typique est celui des corpus de presse ancienne : un OCR peut confondre les colonnes et inverser l'ordre de lecture, ce qui entraîne de longues séquences décalées. Pour l'algorithme d'alignement, ces erreurs se traduisent en cascades de substitutions et d'insertion/suppressions, gonflant artificiellement le CER, alors que pour l'historien intéressé par la recherche lexicale, la reconnaissance des formes de mots resterait partiellement exploitable. Cette discordance montre que CER et WER n'évaluent pas la pertinence de l'OCR du point de vue des usages, mais reflètent seulement une comparaison mécanique. Elle plaide pour le développement de métriques contextualisées capables d'intégrer la segmentation et l'ordre de lecture, dimensions essentielles pour l'exploitation scientifique des corpus patrimoniaux.

Point technique

Calcul du CER et du WER

Soit une séquence de référence R (le *ground truth*) et une séquence prédite H (hypothèse). On définit :

- S : le nombre de substitutions,
- D : le nombre de suppressions (*deletions*),

I : le nombre d'insertions,

- N : le nombre total d'unités dans la référence ($N = |R|$).

La **distance de Levenshtein** correspond à $S + D + I$, soit le nombre minimal d'opérations nécessaires pour transformer R en H .

$$CER = \frac{S + D + I}{N_{\text{caractères}}} \quad WER = \frac{S + D + I}{N_{\text{mots}}}$$

- **CER** : N correspond au nombre total de caractères de la référence.
- **WER** : N correspond au nombre total de mots.

Un score proche de **0 %** indique une reconnaissance quasi-parfaite; au-delà de **20–25 %**, le texte devient difficilement exploitable sans corrections massives.

4. Numérisation du *Journal Officiel* : une politique documentaire partagée entre la BnF et les institutions parlementaires

En 2009, la BnF a ouvert ses marchés de numérisation aux institutions parlementaires, amorçant un partenariat durable avec le Sénat et l'Assemblée nationale pour la mise en ligne de leurs archives. Ce choix, qui prolongeait le programme de « numérisation concertée » lancé quelques années plus tôt, répondait à un double objectif : préserver des ensembles documentaires fragiles et en garantir la diffusion publique. Le Sénat confia ainsi à la BnF la numérisation de ses *Impressions parlementaires* — débats, rapports, annexes — couvrant la Troisième République : les volumes de 1876 à 1905 et de 1910 à 1940 furent traités en priorité, tandis que la tranche 1906-1909 était encore en cours en 2022 . L'Assemblée nationale engagea un processus similaire pour ses débats et comptes rendus, accessibles à la fois sur Gallica et sur son propre site institutionnel. Ces campagnes illustrent la manière dont les chambres parlementaires ne sont pas de simples « producteurs » de sources, mais de véritables acteurs documentaires : en orientant la sélection, en organisant l'accès et en choisissant les canaux de diffusion (Gallica, Retronews, portails institutionnels), elles contribuent à instituer de nouvelles modalités de visibilité du droit et du débat démocratique.

Le **Sénat** a entrepris la numérisation de ses *Impressions parlementaires* (débat, rapports, annexes) couvrant la Troisième République. Ces volumes, progressivement intégrés dans Gallica, prolongent la série du *Journal Officiel* et permettent de reconstituer l'activité législative dans toute sa diversité. L'**Assemblée nationale**, de son côté, a engagé une démarche parallèle avec la mise en ligne de ses débats, à la fois via Gallica et via son propre site institutionnel. Cette articulation produit un maillage documentaire à plusieurs niveaux : d'un côté, Gallica centralise et homogénéise l'accès, dans une perspective patrimoniale ; de l'autre, les sites parlementaires valorisent leurs archives selon leurs propres logiques éditoriales et politiques.

Cette répartition des rôles illustre un modèle hybride de gouvernance documentaire. La BnF définit le cadre et assure l'infrastructure technique ; les assemblées parlementaires apportent leurs fonds et orientent les priorités de mise en ligne. Mais cette complémentarité n'est pas sans tension : les corpus disponibles demeurent lacunaires, et les chercheurs doivent souvent jongler entre Gallica, Retronews et les portails institutionnels pour accéder à une série complète. Comme le notait déjà un guide pratique destiné aux usagers, la consultation du J.O. en ligne exige de composer avec des accès fragmentés et une indexation parfois insuffisante.

En définitive, la numérisation du *Journal Officiel* illustre la logique de coopération encadrée qui structure la politique documentaire française : un équilibre entre centralisation

patrimoniale par la BnF et initiatives propres des institutions productrices, ici les chambres parlementaires. Cette articulation garantit la diffusion publique d'un corpus emblématique, tout en révélant les contraintes techniques et les arbitrages qui accompagnent toute politique de numérisation à grande échelle.

Chapitre 5

Données brutes, données structurées

On l’a vu : la première étape du processus de datafication de sources numérisées et accessibles via les institutions patrimoniales est celle de l’acquisition photographique : un document est scanné ou photographié. On obtient alors une image, fidèle à la source mais muette du point de vue informatique : elle est lisible par l’œil, mais inerte pour un moteur de recherche. La seconde étape, quant à elle, est celle du passage au texte : grâce à la reconnaissance optique de caractères (OCR), l’image est convertie en une suite de signes alphabétiques. On peut alors effectuer des recherches plein texte, mais ce matériau reste linéaire et peu organisé.

La troisième étape, décisive pour l’analyse, est celle de la structuration. Disposer d’un texte est un point de départ, un pré-requis ; mais il s’agit désormais d’identifier dans ce texte des entités, des relations, des attributs — par exemple un nom de sénateur, le sujet de son intervention, le numéro de page correspondant. Ces éléments sont organisés selon un modèle explicite qui rend possible leur comparaison, leur mise en relation et leur analyse. En somme, la structuration est l’opération qui transforme un corpus lisible en données exploitables pour l’analyse. Produire de telles données n’est cependant pas qu’un exercice technique : c’est un travail en trois dimensions — de modélisation (quelle forme donner aux données ?), d’évaluation (comment en juger la qualité ?) et de production (quelles méthodes employer pour transformer un texte en structures fiables ?).

Ce chapitre se concentre sur deux de ces dimensions : comment modéliser des données structurées, et comment les générer à partir de textes. La question de l’évaluation, centrale dans mon stage, quoique abordée ici, fera l’objet d’une partie à part entière.

I. Modéliser des données structurées

La première étape consiste à définir la forme que prendront les données une fois extraites. En effet, la notion de « donnée structurée » recouvre plusieurs types de représentations, plus ou moins adaptées selon les usages et les besoins.

Les *ensembles d'enregistrements* (record sets) correspondent au modèle le plus courant : des collections non ordonnées de tuples, analogues à des tables de base de données. Chaque enregistrement associe une série d'attributs décrivant un objet (nom, fonction, date, etc.). C'est ce format qui est généralement mobilisé dans les tâches d'extraction d'information, telles que la reconnaissance d'entités nommées ou l'extraction de relations. Dans les sciences sociales, on le retrouve par exemple dans les recensements de population, où chaque individu est décrit par un ensemble d'attributs (âge, profession, état matrimonial, lieu de résidence), sans que l'ordre des individus ait d'importance. De même, en histoire politique, la constitution d'un corpus de députés ou sénateurs avec leurs mandats, affiliations et interventions peut être représentée sous forme d'un tel ensemble : une « table » de données où chaque ligne correspond à un parlementaire et chaque colonne à une caractéristique descriptive.

Une variante importante est constituée par les *séquences d'enregistrements* (record sequences), où l'ordre des tuples est significatif. Cette organisation ordonnée peut refléter un critère naturel (par exemple l'ordre temporel) ou une convention éditoriale (comme dans un annuaire ou une table nominative). Dans ces cas, la séquence elle-même porte du sens et facilite certaines analyses (suivi de chronologie, validation croisée, etc.). Ainsi, dans les sciences sociales, l'étude des trajectoires professionnelles ou migratoires repose précisément sur ces séquences : l'enchaînement des postes occupés dans une carrière ou des lieux de résidence successifs permet de dégager des régularités collectives, de mettre en évidence des bifurcations ou de comparer des parcours types. De même, en histoire parlementaire, les *Tables Nominatives* du *Journal Officiel* ordonnent les interventions des sénateurs selon l'année et la pagination, offrant une séquence exploitable pour analyser l'évolution des prises de parole dans le temps ou la récurrence de certains thèmes.

D'autres structures plus complexes existent, comme les **arbres**, qui permettent de représenter des hiérarchies ou des relations imbriquées – par exemple en analyse syntaxique –, et les **graphes**, qui offrent une grande flexibilité pour représenter des connaissances consolidées, notamment dans les ontologies ou graphes de connaissances. Ces structures sont néanmoins très intéressantes, car elles bénéficient de solides sophistications mathématiques de la théorie des graphes, de l'algèbre linéaire voire de la topologie appliqué aux données. On peut ainsi détecter des communautés (clustering), mesurer la centralité ou l'influence de certains nœuds dans un réseau, ou encore identifier des chemins de diffusion ou de dépendance entre entités.

En sciences humaines, ces méthodes permettent par exemple de reconstituer des réseaux de sociabilité, d’analyser la circulation d’idées ou de suivre l’évolution de liens institutionnels. Néanmoins, l’évaluation de ces structures, en particulier les graphes, dépasse généralement le champ de l’extraction d’information proprement dite.

Dans le cas qui nous occupe, à savoir l’extraction d’informations à partir des documents parlementaires, les *ensembles et séquences d’enregistrements* sont les plus pertinents. Ils correspondent directement à la structure des *Tables nominatives*, où l’on recense des individus (sénateurs), des événements (leurs interventions) et des attributs associés (objets des débats, références de page). C’est donc sur ce type de représentation que nous concentrons notre attention dans la dernière partie du mémoire. Cependant, la modélisation n’est en pratique pas qu’un exercice intellectuel. L’expérimentation nous renseigne et nous permet d’amender la façon de voir les données, de les mettre en relation. Tout dépend de ce à quoi on tient savoir : si la relation entre les sénateurs importent plus que leur trajectoire intellectuelle, alors un graphe sera plus pertinent qu’une séquence d’enregistrements. Encore une fois, la dimension technique de la modélisation repose sur des enjeux évaluatifs de la recherche.

II. Produire des données structurées à partir de texte

Enfin, la question centrale demeure : comment générer des données structurées à partir de texte brut ? Trois grandes familles d’approches dominent : les approches par *pattern matching*, les *approches extractives* et les *approches génératives*¹.

Les approches par *pattern matching* consistent à rechercher dans un texte brut des séquences de caractères ou de mots qui correspondent à des motifs préalablement définis. Elles reposent sur l’idée que certaines informations suivent des régularités formelles ou typographiques que l’on peut capturer par des règles explicites. Les *expressions régulières* – ou *Regex* – en constituent l’exemple le plus connu : elles permettent de détecter des dates, des numéros, ou encore des patronymes en fonction de leur forme.

Les approches extractives reposent sur l’identification directe, dans le texte, des fragments qui correspondent aux champs d’une structure cible. Elles peuvent être mises en œuvre via des règles (expressions régulières, patrons linguistiques) ou via des modèles supervisés d’étiquetage de séquence, comme les CRF [5] ou les modèles encodeurs-transformers (BERT, RoBERTa) [4]. Ces approches présentent l’avantage de limiter le risque d’hallucinations : elles ne « fabriquent » pas d’information absente du texte, puisqu’elles ne font que sélection-

¹S. Scott Graham, Zoltan P. Majdik et Dave Clark, « Methods for Extracting Relational Data from Unstructured Texts Prior to Network Visualization in Humanities Research », *Journal of Open Humanities Data*, 6–1 (nov. 2020), DOI : 10.5334/johd.21.

ner et classer ce qui existe déjà. En revanche, elles nécessitent un entraînement spécifique à la tâche, ce qui implique un corpus annoté, des ressources computationnelles et du temps.

Les approches génératives, en revanche, considèrent l'extraction comme une opération de traduction : le texte source est « traduit » dans un format cible (JSON, CSV, XML, etc.). Les modèles autoregressifs, et en particulier les LLMs, ont ravivé l'intérêt pour cette voie grâce à leur capacité à généraliser en *zero-shot* ou *few-shot* [1, 20, 21]. Des techniques récentes permettent même de contraindre la génération à respecter des formats prédéfinis, par exemple en filtrant dynamiquement les tokens pour ne retenir que ceux compatibles avec une grammaire donnée [23]. Cette flexibilité rend possible la production de structures complexes et imbriquées, tout en captant des informations implicites. Leur inconvénient majeur reste toutefois le risque d'hallucinations, c'est-à-dire de données inventées ou inférées à tort, souvent difficiles à détecter automatiquement.

Dans notre étude, nous avons choisi d'explorer l'efficacité des approches génératives pour traiter les structures répétitives des *Tables nominatives*. Nous mettons à profit les capacités *zero-shot* des LLMs pour évaluer dans quelle mesure ils peuvent produire des données structurées fiables et interopérables à partir de corpus parlementaires. Cependant, il convient de motiver ce choix en abordant les différentes catégories de générations de données que nous venons de donner.

1. Approche à motifs explicites : les ReGex

L'une des premières méthodes mobilisées pour extraire de l'information à partir de textes repose sur l'usage des expressions régulières (Regular Expressions, ou RegEx). Développées dès les années 1950 dans le champ de la théorie des automates, elles se sont imposées comme un outil incontournable pour le traitement automatique de texte. Leur principe est simple : définir un motif formel (pattern) qui décrit la forme que doit prendre une séquence de caractères afin qu'elle soit reconnue par le système. Par exemple, un motif tel que `\d{4}` permet de détecter toutes les occurrences de suites de quatre chiffres, ce qui peut correspondre à des dates dans un texte.

Cette approche présente des avantages certains. Les RegEx sont rapides à exécuter et extrêmement précises dès lors que l'on connaît à l'avance la forme des données recherchées. Elles sont également peu coûteuses en ressources computationnelles et ne nécessitent aucun entraînement supervisé : il suffit de concevoir le motif pour capturer l'information. Dans le cas de documents semi-structurés ou normés (par exemple la détection de numéros de lois, de dates ou de références bibliographiques), les expressions régulières restent un outil efficace. Elles peuvent aussi servir de composant de prétraitement dans des pipelines plus complexes, en nettoyant ou en normalisant certaines informations avant de les confier à des modèles plus

avancés.

Toutefois, leur rigidité limite fortement leur portée. La conception d’une RegEx efficace suppose que l’on ait une connaissance préalable de la forme exacte de ce que l’on cherche — or, dans le cas de sources historiques, cette condition est rarement remplie. Les variations typographiques, les abréviations, les fautes de frappe ou encore les artefacts liés à l’OCR (caractères mal reconnus, coupures de lignes, ligatures) rendent les motifs fragiles. Une expression trop stricte manquera des cas pertinents ; une expression trop souple capturera du bruit et produira des faux positifs. Les approches de recherche floue (fuzzy matching) ont été développées pour pallier cette rigidité, mais elles ne permettent que de retrouver ce que l’on connaît déjà à l’avance, et ne s’adaptent pas à des contextes entièrement nouveaux. En d’autres termes, l’approche reste fondamentalement fermée. Elle suppose déjà une connaissance assez fine non pas seulement du « contenu historique » des sources ; mais des suites d’opérations techniques de transduction informationnelle qui commencent à la transcription de l’acte parlementaire au texte OCRisé, en passant par les processus la composition linotypique des imprimeries du *Journal Officiel* et des stratégies d’acquisition numérique.

L’utilisation des RegEx peut être enrichie par des patrons linguistiques plus élaborés (par exemple des grammaires ou des dépendances syntaxiques), par des listes de référence (ou gazetteers, contenant des noms propres, des toponymes, etc.), ou encore par des règles de post-traitement visant à corriger ou normaliser les sorties. Ces ajouts offrent davantage de robustesse et améliorent la précision, mais ils n’échappent pas au principal écueil : la nécessité de concevoir manuellement l’ensemble des règles, ce qui devient rapidement coûteux et peu scalable à grande échelle. L’avantage de ces approches reste toutefois leur explicabilité : contrairement aux modèles neuronaux, les règles définies sont transparentes et permettent de prédire le comportement du système.

Dans le cadre du *Journal Officiel* et des *Tables nominatives*, l’approche par RegEx peut constituer un point de départ utile pour détecter des éléments aux formats relativement standardisés — comme les numéros de page, les années, ou certaines abréviations récurrentes. Cependant, elle montre rapidement ses limites pour capturer la sémantique implicite : qui parle, sur quel sujet, dans quel contexte. C’est précisément ce passage à une structuration plus riche, allant au-delà de la simple détection de motifs de surface, qui justifie le recours à des approches plus sophistiquées.

2. Approches extractives : BERT

Face aux limites des expressions régulières, la recherche est passée à une nouvelle étape : confier à des modèles statistiques puis neuronaux la tâche de repérer directement, dans un texte, les éléments d’intérêt. Le principe est simple à imaginer : c’est comme si l’on entraînait

un étudiant à surligner systématiquement les noms de personnes, les dates ou les thèmes dans un document. Chaque mot ou groupe de mots reçoit ainsi une étiquette (« nom de sénateur », « fonction », « numéro de page », etc.), ce qui permet de transformer le texte en une série d'enregistrements exploitables.

Au départ, ces systèmes utilisaient des méthodes statistiques assez rigides : on décrivait chaque mot par ses caractéristiques visibles (comme sa terminaison, sa majuscule initiale, son voisinage immédiat) et le modèle apprenait à reconnaître des motifs. Cela marchait, mais seulement si les données ressemblaient beaucoup à celles utilisées pour l'entraînement.

Avec l'apprentissage profond, on est passé à un niveau supérieur. Les réseaux de neurones « séquentiels » (par exemple les LSTM) sont capables de tenir compte de la phrase entière, et donc de mieux comprendre le contexte d'un mot. Ainsi, le système ne se contente pas de voir que « budget » est un substantif, il comprend qu'il apparaît dans un débat sur les finances publiques.

L'arrivée des **Transformers**, et en particulier de **BERT**, a encore changé la donne. Pour vulgariser : BERT lit un texte en tenant compte simultanément de tout son contexte, en regardant à gauche et à droite de chaque mot, comme si le système surlignait en comprenant la phrase entière plutôt que mot par mot. Ce modèle a été entraîné sur des millions de phrases, ce qui lui donne une « intuition linguistique » qu'il peut réutiliser sur de nouvelles tâches, même dans des domaines spécialisés comme les débats parlementaires.

Les avantages sont clairs : ces modèles reconnaissent mieux les entités malgré les variations de style ou les petites erreurs d'OCR, et ils nécessitent beaucoup moins de travail manuel pour concevoir des règles. Cependant, il y a un revers : ils ne fonctionnent bien que si l'on dispose d'un jeu d'exemples annotés pour les entraîner sur la tâche précise (par exemple, un lot de pages du *Journal Officiel* où les sénateurs et les objets d'intervention sont déjà identifiés). Or, produire ces annotations coûte du temps et de l'expertise. De plus, l'entraînement suppose une certaine puissance de calcul (GPU, logiciels spécialisés), pas toujours disponible dans des projets en sciences humaines.

En résumé : les approches extractives modernes comme BERT sont de véritables surligneurs automatiques très performants, mais ils demandent une phase préparatoire coûteuse (annotations + infrastructure). C'est ce qui explique que les chercheurs en histoire ou en sciences sociales se tournent de plus en plus vers les modèles génératifs (LLMs), qui contournent en partie ce verrou.

3. Approches génératives : les LLMs

L'émergence des **grands modèles de langage (LLMs)** – tels que GPT, Claude, LLaMA ou Mistral – a transformé le champ de l'extraction d'information. Contrairement

aux approches dites extractives, qui consistent à surligner et classer des portions du texte existant, les LLMs reposent sur un principe génératif : ils produisent directement une sortie textuelle, guidée par des instructions. L'extraction d'information n'est donc plus envisagée comme une classification locale, mot par mot, mais comme une reformulation structurée : le modèle lit le texte, en sélectionne les éléments pertinents et les restitue sous une forme organisée, prête à l'analyse.

Le cœur de cette approche réside dans l'instruction donnée au modèle, ce que l'on appelle désormais un *prompt*. Celui-ci peut préciser le type de sortie attendu, qu'il s'agisse d'un tableau, d'un schéma en JSON ou d'une liste hiérarchisée, et inclure des exemples pour orienter la génération. Ainsi, à partir d'un passage du *Journal Officiel* mentionnant « M. Dupont intervient au sujet du budget des chemins de fer (p. 234) », le modèle ne se contente pas d'indiquer les entités en jeu ; il est capable de reconstruire une représentation explicite de l'information, par exemple : « nom » : « Dupont », « sujet » : « budget des chemins de fer », « page » : 234. Cette capacité à produire une structure à la volée marque un changement de paradigme. L'utilisateur ne construit plus un modèle spécialisé via un entraînement complexe, mais formule une consigne linguistique à laquelle le modèle s'adapte immédiatement.

Cette approche présente plusieurs atouts. Elle se distingue d'abord par sa flexibilité : un même modèle peut accomplir une grande variété de tâches, qu'il s'agisse d'extraire des entités, de résumer des documents ou de convertir un texte en tableau, sans nécessiter de jeu de données annoté ni d'entraînement spécifique. Elle se caractérise également par sa rapidité de mise en œuvre : quelques *prompts* bien conçus suffisent à obtenir des résultats exploitables, ce qui réduit considérablement les coûts et les délais d'un projet. À cela s'ajoute une robustesse linguistique liée au pré-entraînement massif de ces modèles sur d'immenses corpus : ils reconnaissent des formulations inhabituelles, des variations lexicales ou syntaxiques, et produisent malgré tout une sortie cohérente. Enfin, leur capacité à générer directement dans des formats structurés tels que le JSON, le CSV ou l'XML rend leurs productions immédiatement intégrables dans des bases de données ou des environnements analytiques.

Mais ces avantages ne doivent pas masquer certaines limites. Les sorties générées ne sont pas toujours stables : un même prompt appliqué à des passages similaires peut donner lieu à des structures divergentes, ce qui complique l'automatisation complète du processus. Les modèles sont en outre sujets aux « hallucinations », c'est-à-dire qu'ils peuvent inventer des données absentes du texte original, une dérive particulièrement problématique du point de vue scientifique. La qualité des résultats dépend aussi de la formulation du prompt, qui devient un paramètre méthodologique central et parfois délicat à maîtriser. Enfin, si l'usage ponctuel d'un LLM est peu coûteux, le traitement de corpus volumineux peut rapidement représenter un investissement financier ou technique non négligeable, selon que l'on mobilise

des API commerciales ou des modèles libres installés localement.

Dans le domaine des sciences humaines et sociales, ces modèles ouvrent néanmoins des perspectives inédites. Ils permettent d’extraire automatiquement des informations structurées à partir de corpus historiques, en évitant l’étape fastidieuse et coûteuse de l’annotation manuelle. Des expérimentations récentes ont déjà montré leur potentiel pour la transcription, l’annotation ou l’extraction d’entités dans des fonds patrimoniaux. Pour le *Journal Officiel* et ses *Tables nominatives*, ils offrent la possibilité de transformer directement des listes semi-structurées en tableaux exploitables, en capturant les noms des sénateurs, les objets d’intervention et les références paginées. Une tâche autrefois fastidieuse, nécessitant un dépouillement patient et souvent incomplet, devient ainsi automatisable à grande échelle.

En définitive, les approches génératives déplacent le centre de gravité de l’extraction d’information. Là où l’on cherchait auparavant à construire des modèles spécialisés et rigides, il s’agit désormais d’orchestrer une génération encadrée par des consignes précises. Cette plasticité ouvre un champ nouveau pour la capture sémantique des corpus textuels, mais elle suppose d’accompagner leur usage de garde-fous méthodologiques, afin de garantir la fiabilité et la traçabilité des données produites.

III. La sortie structurée via LLM pour le *Journal Officiel*

Il est intéressant de revenir sur l’approche générative car c’est celle-ci qui a été retenue. En effet : l’application des approches génératives par grands modèles de langage, dans le cas du *Journal Officiel*, et plus spécifiquement des *Tables nominatives* du Sénat, a l’avantage d’être simple et rapide à mettre en place. Ces tables, qui fonctionnent comme des index annuels de l’activité parlementaire, présentent une organisation qui semble régulière : elles listent les noms des sénateurs, précisent le sujet de leurs interventions et renvoient aux pages correspondantes. Cette apparente homogénéité masque cependant une série de difficultés. Cette partie ne présentera pas les détails techniques, mais quelques enjeux techniques et avantages à considérer, lesquelles seront développés dans la partie suivante. La mise en page, par exemple, peut varier d’une année à l’autre ; les noms sont parfois abrégés ou tronqués ; et les textes portent les stigmates d’un OCR imparfait, introduisant du bruit ou des confusions typographiques. À cela s’ajoute la diversité des formulations, qui rend incertaine toute tentative de repérage par motifs fixes. Capturer la sémantique de ces tables suppose donc de dépasser la simple reconnaissance de structures formelles et d’accéder à une représentation organisée et exploitable de l’information.

1. Simplicité

Les LLMs offrent un compromis assez intéressant. Contrairement aux approches extractives classiques, qui nécessitent la constitution d'un corpus annoté et l'entraînement d'un modèle spécialisé, les LLMs peuvent être mobilisés rapidement avec un simple appel d'API. Il suffit de leur fournir quelques exemples de sortie attendue au sein d'un prompt pour orienter leur génération. Cette souplesse en fait une solution pragmatique, adaptée à des projets exploratoires en sciences humaines où le temps et les ressources d'annotation peuvent être limités. Une campagne d'annotation peut être longue voire approximative, sans accord inter-annotateur qui permet de désambigüiser l'étiquetage des données. De plus, le recours à ces API accessibles ou à des modèles libres déployés localement permet de réduire les coûts techniques initiaux, tout en laissant aux chercheurs la possibilité de se concentrer sur les choix méthodologiques plutôt que sur les contraintes d'infrastructure.

2. Sortie structurée, génération structurée

C'est ici qu'entre en jeu une distinction essentielle : celle entre **sortie structurée** et **génération structurée**. Dans le premier cas, dit de sortie structurée, on exploite la capacité du LLM à imiter des formats qu'il a déjà rencontrés lors de son entraînement. Au lieu de laisser parler le LLM avec la prolixité qu'on lui connaît, on le « guide » par le prompt en lui imposant un format attendu — par exemple un dictionnaire JSON comportant les champs « nom » : « ... », « intervention » : « ... », « page » : « ... ». Le modèle, plutôt que de produire une réponse discursive en langage naturel, ajuste alors son texte pour respecter ce format. C'est une manière pragmatique et peu coûteuse d'obtenir des données directement exploitables. La génération structurée va un pas plus loin : elle ne se contente pas de guider la sortie a posteriori, mais contraint en amont les chemins de génération possibles. Techniquement, il s'agit d'agir sur les probabilités de production des tokens, en forçant le modèle à n'émettre que des suites de symboles compatibles avec une grammaire donnée, comme JSON ou XML. Cette mise « sur rails » de la génération, qu'on peut comparer à un automate fini qui valide chaque token au moment où il est choisi, permet d'éviter les écarts ou les incohérences de format. Dans mon cas, comme on le verra dans la partie suivante, la première approche aura été choisie : une sortie structurée imposée par le prompt, sans recours à une génération contrainte au niveau des probabilités. L'avantage de ces deux méthodes, et particulièrement de la sortie structurée, est de rendre possible une intégration directe dans des pipelines d'analyse. Le texte brut devient immédiatement une table exploitable ou un ensemble d'enregistrements importables dans une base relationnelle. En outre, cette structuration assure la traçabilité : chaque donnée extraite peut être reliée au fragment de texte d'où elle provient, ce qui rend

possible une vérification par l'historien.

Il reste néanmoins essentiel de souligner les limites et les précautions que cette approche implique. Les sorties produites par les LLMs ne sont pas toujours stables : un même prompt appliqué à des passages semblables peut générer des structures divergentes, incomplètes ou incohérentes. Les modèles peuvent aussi souffrir d'« hallucinations », inventant des informations absentes du texte original. Enfin, la qualité des résultats dépend fortement de la formulation du prompt, dont de petites variations peuvent entraîner de grandes différences dans les réponses. Pour ces raisons, la mise en place de protocoles de validation est indispensable. Cela peut passer par un contrôle humain sur des échantillons, par l'application de règles automatiques de cohérence (par exemple vérifier qu'un numéro de page est bien un entier valide), ou encore par l'alignement systématique des sorties avec des référentiels externes, tels que les listes officielles des sénateurs d'une année donnée. Ces garde-fous garantissent que les données produites conservent leur fiabilité scientifique et puissent être mobilisées dans le cadre d'une recherche historique rigoureuse. Une fois obtenues, ces données structurées ouvrent un large éventail de possibilités : suivre longitudinalement l'activité des sénateurs, mesurer la fréquence et la thématique de leurs interventions, ou encore croiser ces informations avec d'autres corpus, tels que les débats parlementaires complets ou les archives législatives. Là où le dépouillement manuel demeurerait fastidieux et fragmentaire, la structuration par LLM transforme le *Journal Officiel* en un matériau interrogeable, apte à nourrir des analyses sérielles, des visualisations de réseaux d'intervenants ou des comparaisons thématiques.

Cependant, si l'utilisation des LLMs pour la capture sémantique du *Journal Officiel* constitue une approche pragmatique, combinant rapidité de mise en œuvre et faible coût – notamment parce qu'elle évite la lourde étape d'annotation –, elle comporte des risques majeurs. Les modèles peuvent produire des hallucinations, c'est-à-dire des sorties erronées, incomplètes ou inventées, qui fragilisent leur usage scientifique. Dès lors, l'enjeu central n'est plus seulement de produire des données, mais de mesurer le degré de confiance que l'on peut accorder aux résultats. Cette évaluation doit être envisagée à l'échelle de toute la chaîne de traitement : depuis l'image OCRisée jusqu'aux données structurées produites par le modèle.

Troisième partie

Expérimenter et évaluer pour comprendre : une démarche historienne outillée

Chapitre 6

Evaluer le protocole de capture sémantique

De l'importance de Valuation, évaluation. La question de la métrique. Article co-écrit.

Chapitre 7

Expérimentations

Un travail d'exploration technique a été fait. Une fois la tâche définie (éval de la sortie structurée). TED, donut, Métrique de l'inégalité triangulaire.

Chapitre 8

Livrable

I. Extraction guidée par schéma des interventions parlementaires à partir des index historiques

1. Les Tables nominatives du Sénat de 1931

Il existe une édition des *Tables du Journal Officiel* pour chaque année, comprenant typiquement environ 450 pages dans les années 1930. La section intitulée *Tables des noms* — qui inclut à la fois le Sénat et la Chambre des députés — s’étend sur une quarantaine de pages, dont environ quinze pour la partie Sénat.

Pour l’année 1931, les *Tables des noms* du Sénat couvrent 14 pages et comptent environ 300 entrées, chacune correspondant à une intervention en assemblée. Chaque entrée est associée à un orateur et détaille différents types d’actions (demandes d’interpellation, discussions de projets de loi, lecture de rapports de commission, dépôt d’amendements, etc.), accompagnées d’une référence de page renvoyant à la transcription complète de l’intervention.

Ces transcriptions sont publiées dans les *Débats parlementaires* du Sénat. Les tables sont donc liées fonctionnellement aux transcriptions par la pagination. Comme la numérotation des pages est continue sur toute l’année, chaque référence permet de dater précisément l’intervention correspondante.

2. Chaîne de traitement pour l’extraction structurée guidée par schéma

Malgré les avancées récentes des grands modèles de vision et langage (LVLMs), leurs performances *end-to-end* en zéro-shot restent insuffisantes pour des tâches d’OCR à haute précision. Pour contourner cette limite, nous adoptons une chaîne de traitement simple,

exploitant les forces de composants spécialisés afin de maximiser la précision globale de l'extraction.

1. Chaque page image est d'abord traitée indépendamment par le moteur OCR **PERO** [8, 10, 11] pour détecter et transcrire le texte.
2. Compte tenu des difficultés persistantes de segmentation de mise en page, nous produisons trois variantes de transcription par page afin de refléter la variabilité de ce type de pipeline (détaillées en section 4.1).
3. Une fois les transcriptions obtenues, nous concaténons le texte issu de toutes les pages pertinentes pour former un flux unique. Celui-ci est fourni en entrée à un LLM, chargé de produire les données structurées cibles.

Dans nos expérimentations, pour des raisons pratiques, chaque page est traitée indépendamment, mais la méthode peut être étendue à des contextes multi-pages.

Bien que les LLMs puissent être incités à générer des sorties structurées, il est essentiel de contraindre leurs générations au format attendu. Parmi les méthodes existantes, la plus efficace repose sur le filtrage des tokens valides au moment de l'inférence à l'aide d'un validateur externe (par exemple un automate fini) [23]. Cette capacité est disponible dans certaines API commerciales étendues.

Notre processus d'extraction s'appuie donc sur :

- un texte prétraité par OCR,
- un schéma prédéfini (JSON),
- un prompt naturel,
- et une API supportant les sorties contraintes.

Pour cette étude, nous avons retenu l'API **Mistral**, avec le modèle *Ministral 8B Instruct v2410* [16], en raison de ses bonnes performances *zero-shot*, de son coût modéré et de la disponibilité publique de ses poids à des fins de recherche .

3. Modélisation des données et définition du schéma

L'objectif principal est d'extraire des informations structurées sur l'activité parlementaire du Sénat français en 1931, dans la perspective de construire une frise interactive représentant la densité d'interventions au cours du temps. Pour garantir la fiabilité et l'interprétabilité de cette visualisation, il est nécessaire de fournir des indicateurs clairs de qualité d'extraction.

Le lien direct entre fiabilité de l'extraction et confiance dans les réponses à des questions de recherche demeure un défi. Nous concentrons donc notre évaluation sur des métriques bien définies, qui quantifient la similarité entre structure prédite et structure de référence (*ground truth*). Ces métriques ne rendent pas encore compte de l'impact sémantique des erreurs, mais constituent une base transparente d'évaluation.

La tâche d'extraction repose sur l'identification des entrées individuelles dans les *Tables nominatives* — c'est-à-dire les noms des sénateurs et leurs références de pages. Ces numéros de pages servent d'indicateurs temporels indirects, puisque la pagination est continue sur l'année. L'information extraite est représentée en JSON, format à la fois structuré et interopérable, permettant un traitement ultérieur (CSV, analyses).

Le schéma de données utilisé pour guider le LLM est défini au niveau des noms d'orateurs et de leurs références de pages, ce qui suffit à notre objectif. Nous utilisons la bibliothèque **Pydantic** pour formaliser ce schéma de manière compatible JSON, avec validation stricte des types et descriptions intégrées. Ces descriptions jouent le rôle d'étiquettes sémantiques, améliorant la clarté du prompt et l'orientation du modèle.

4. Construction du prompt pour l'extraction

Le prompt fourni au LLM (cf. Annexe B) vise à guider l'extraction des participants (sénateurs, ministres) et de leurs références de pages à partir du texte. Sa structure est la suivante :

- **Définition de la tâche** : préciser que chaque entrée correspond à une personne ayant participé aux activités du Sénat (sénateurs, ministres, etc.), dont il faut extraire le nom et les références de pages.
- **Clarification des termes** : donner des définitions pour des termes clés comme « entrée » ou « action », afin d'éviter toute ambiguïté.
- **Cas particuliers** : indiquer comment traiter les cas de renvois d'index (sans numéros de pages, mais renvoyant vers une autre entrée) et les entrées fragmentées sur plusieurs pages (ignorées pour simplifier cette première étude).
- **Instructions de formatage** : spécifier les règles de présentation des noms (prénom entre parenthèses après le nom de famille) et des références de pages.

Le prompt pourrait être encore amélioré en y intégrant davantage de contexte historique ou d'exemples représentatifs (*few-shot prompting*).

5. Raffinement itératif du schéma et du prompt

Au cours de l'étude, le schéma et le prompt ont été ajustés de manière itérative. En effet, le LLM proposait parfois spontanément des manières alternatives — et parfois plus efficaces — de structurer l'information extraite. Par exemple, il avait tendance à dédupliquer les références de pages répétées pour un même orateur, simplifiant ainsi le résultat au-delà du schéma initial.

La construction du *ground truth* a donc dû trouver un équilibre entre respect strict du schéma formel et prise en compte des tendances de structuration du LLM.

Afin d'éviter tout biais, tous les ajustements de schéma et de prompt ont été réalisés uniquement sur une page de développement (dite « page 02 »). Les autres pages ont servi exclusivement aux tests finaux, suivant les bonnes pratiques en apprentissage automatique.

À l'avenir, ce processus pourrait être automatisé ou enrichi par des stratégies systématiques d'ingénierie de prompts.

II. Expériences

La configuration expérimentale a été mise en place à travers une phase de développement initiale, durant laquelle le schéma de données, les instructions du prompt et les données de référence structurées pour une page de développement ont été affinés de manière itérative. Une fois cette phase finalisée, nous avons appliqué le modèle de base à un ensemble plus large de pages, puis corrigé manuellement les sorties afin de construire un *ground truth* impartial pour l'évaluation.

Cette section détaille le jeu de données obtenu, les variantes générées pour l'analyse, ainsi que le protocole d'évaluation adopté pour mesurer rigoureusement la qualité des prédictions.

1. Jeu de données

Les données de référence (*ground truth*) ont été construites pour évaluer de manière rigoureuse la qualité d'extraction à différents niveaux de fidélité OCR. Pour chaque page sélectionnée, trois variantes distinctes issues du moteur OCR **PERO** [8, 10, 11] ont été générées :

1. une version corrigée manuellement (or servant de standard de référence),
2. une version basée sur une segmentation manuelle de la mise en page,
3. une version brute, sans correction ni segmentation.

Ce dispositif permet d'évaluer systématiquement la robustesse du pipeline face au bruit et aux artefacts de mise en page.

Un échantillon aléatoire de cinq pages consécutives a été choisi pour transcription et annotation manuelles. Comme les entrées peuvent s'étendre sur plusieurs pages, certaines se retrouvent tronquées. Dans ces cas, le LLM a été explicitement instruit d'ignorer les éléments incomplets. Ce choix reflète les défis réalistes de l'extraction, où une prise en compte multi-pages (ou en flux continu) serait nécessaire en production, mais dépasse le cadre de cette étude.

Chaque page a été traitée indépendamment afin d'éviter tout biais lié au contexte séquentiel. Cela a parfois conduit à des extractions débutant en milieu d'entrée, fournissant au modèle des informations tronquées et testant sa capacité à interpréter des contextes partiels. Bien que les documents sources soient généralement bien numérisés, certaines distorsions (plis, coupures) introduisent des difficultés réalistes, révélant les limites du modèle en conditions imparfaites.

Les sorties structurées ont été générées avec le modèle **Ministral 8B**, en utilisant un prompt fixe et un schéma défini via Pydantic pour garantir la cohérence. Une température nulle a été choisie pour obtenir des résultats déterministes. Pour chaque page et variante OCR, le modèle a produit des sorties JSON, ensuite comparées aux représentations de référence construites manuellement.

L'évaluation porte sur **109 entrées réparties sur cinq pages**, chacune testée dans les trois conditions OCR.

2. Protocole d'évaluation des sorties structurées

L'objectif de l'évaluation est de comparer rigoureusement les sorties produites par le LLM (notées P) *against* *ground truth* (notées G). Comme décrit en section 3.3, chaque instance de donnée correspond à une liste d'entrées, chacune constituée d'un nom d'orateur et d'une liste de pages référencées.

Un défi majeur tient au fait que le modèle peut produire le bon ensemble d'entrées, mais dans un ordre différent, ou avec de légères variations structurelles. Pour résoudre cela, nous adoptons une stratégie d'alignement flexible inspirée de [2, 7], utilisant le transport optimal pour établir une correspondance *one-to-one* entre prédictions et référence. Cette approche neutralise la contrainte d'ordre et tolère des divergences mineures, permettant une évaluation robuste.

a. Distance au niveau des entrées et appariement optimal

Pour comparer les entrées prédites et de référence, nous définissons une distance normalisée $d_e(g_i, p_j)$ qui combine deux composantes :

- **Nom de l'orateur (texte)** : distance de Ratcliff/Obershelp (basée sur la plus longue sous-chaîne commune), après minuscule et suppression des espaces. La distance normalisée $d_n(g_i, p_j) \in [0, 1]$ vaut 0 pour un match exact et 1 pour une dissimilarité totale.
- **Pages référencées (ensembles)** : distance Intersection-over-Union (IoU) :

$$d_p(g_i, p_j) = 1 - \frac{|ref_pages(g_i) \cap ref_pages(p_j)|}{|ref_pages(g_i) \cup ref_pages(p_j)|}$$

- **Distance d'entrée** :

$$d_e(g_i, p_j) = d_n(g_i, p_j) \times d_p(g_i, p_j)$$

Un appariement *one-to-one* entre prédictions et vérité terrain est alors établi par transport optimal [19], minimisant la distance totale et fournissant une base rigoureuse pour l'évaluation.

b. Limites des métriques classiques : précision, rappel et F1

Les métriques usuelles (précision, rappel, F1) sont couramment utilisées pour évaluer les tâches d'extraction. Cependant, dans notre protocole, où les entrées sont alignées par transport optimal, elles deviennent trompeuses :

- l'appariement injectif force une correspondance complète, ce qui maximise artificiellement la précision,
- le rappel ne reflète pas les entrées manquantes ou ajoutées,
- la F1 hérite de ces biais et surestime les performances.

c. Integrated Matching Quality (IMQ) : une métrique robuste

Pour dépasser ces limites, nous exploitons directement la distance d_e pour définir une qualité $q_i = 1 - d_e(g_i, p_i)$, qui reflète la proximité entre une entrée prédite et sa référence.

Plutôt que de fixer un seuil arbitraire pour décider du « bon » appariement, nous calculons la proportion de correspondances de qualité supérieure à un seuil t , puis intégrons sur tout l'intervalle $[0, 1]$.

$$IMQ = \int_0^1 F(t) dt$$

où $F(t)$ est la fraction des correspondances de qualité $q_i \geq t$.

L'IMQ résume ainsi la qualité globale des appariements, récompensant à la fois leur nombre et leur proximité. Un score de 1 indique un alignement parfait. Cette métrique continue, indépendante de seuils arbitraires, est particulièrement adaptée aux sorties LLM, où de légères divergences sont fréquentes même sous fortes contraintes structurelles.

III. Résultats et analyse

Nous avons appliqué notre méthode d'appariement sur cinq pages distinctes (109 entrées), chacune traitée indépendamment et présentant des qualités OCR variables. Le tableau ci-dessous présente les résultats pour chaque page OCRisée sans segmentation ni correction, avec les tailles des ensembles de référence et prédits, ainsi que le nombre de correspondances retenues par transport optimal :

| Source | Précision (biaisée) | Rappel (biaisé) | IMQ | Entrées de référence | Entrées prédites | Correspondances |
|---------|---------------------|-----------------|--------|----------------------|------------------|-----------------|
| page 02 | 1.0000 | 0.9565 | 0.9059 | 23 | 22 | 22 |
| page 03 | 1.0000 | 1.0000 | 0.8928 | 25 | 25 | 25 |
| page 04 | 1.0000 | 1.0000 | 0.9591 | 19 | 19 | 19 |
| page 05 | 1.0000 | 1.0000 | 0.8636 | 19 | 19 | 19 |
| page 10 | 1.0000 | 1.0000 | 0.8193 | 23 | 23 | 23 |

Toutes les pages affichent une précision et un rappel « biaisés » parfaits ; mais comme discuté en section précédente, ces métriques sont limitées car elles découlent directement de l'appariement injectif. Elles ne reflètent pas la qualité réelle des alignements.

L'IMQ, en revanche, fournit une évaluation plus fine, en capturant la distribution des qualités de correspondances. Pour toutes les pages traitées, les scores IMQ restent élevés (entre 0.8193 et 0.9591), montrant une homogénéité forte entre correspondances. L'IMQ évalue donc à la fois la complétude et la proximité sémantico-syntaxique des appariements, jouant un rôle hybride entre rappel qualitatif et précision pondérée.

1. Variations entre pages

Pages 5 et 10 : IMQ plus bas, lié à des incohérences typographiques. De nombreux pré-noms n'y sont pas mis entre parenthèses après le nom, contrairement à l'attendu dans le ground truth* (21 % des entrées sur la page 5, 39 % sur la page 10). Cela augmente artificiellement la distance textuelle et dégrade la qualité perçue des correspondances.

- **Page 3** : malgré une précision/rappel parfaits, IMQ plus faible (0.8928), dû à des problèmes OCR causés par un pli dans la reliure, générant du bruit visuel.
- **Page 2** : IMQ élevé (0.9059) malgré un rappel imparfait. Cela s'explique par un biais d'échantillonnage : le prompt avait été calibré sur cette page, ce qui améliore artificiellement la performance. Toutefois, les résultats solides sur la page 4 (IMQ = 0.9591) confirment la robustesse du dispositif.

Un cas particulier : sur la page 2, une personne est mentionnée deux fois (comme sénateur et comme ministre). Le *ground truth* distingue ces deux entrées, tandis que le LLM les fusionne. Cela réduit artificiellement le rappel mais correspond à une rationalisation fonctionnelle du modèle.

2. Comparaison avec OCR « parfait »

Lorsque l'on compare avec l'OCR jugé « parfait » (corrigé manuellement), les résultats s'améliorent globalement :

| Source | Précision (biaisée) | Rappel (biaisé) | IMQ | Entrées de référence | Entrées prédites | Correspondances |
|---------|---------------------|-----------------|--------|----------------------|------------------|-----------------|
| page 02 | 1.0000 | 1.0000 | 0.9513 | 23 | 23 | 23 |
| page 03 | 1.0000 | 1.0000 | 0.9430 | 25 | 25 | 25 |
| page 04 | 1.0000 | 1.0000 | 0.9821 | 19 | 19 | 19 |
| page 05 | 1.0000 | 1.0000 | 0.8778 | 19 | 19 | 19 |
| page 10 | 1.0000 | 1.0000 | 0.8966 | 23 | 23 | 23 |

Dans certains cas, les versions OCR bruitées donnent des résultats paradoxalement meilleurs. Par exemple, les en-têtes courants capturés par l'OCR bruité fournissent un contexte utile pour les entrées tronquées en début de page. Ainsi, sur la page 2, le LLM a correctement reproduit la double mention (sénateur/ministre), alors que l'OCR corrigé ne l'a pas permis.

Cela montre que la performance dépend non seulement du LLM, mais aussi de l'adéquation entre ses comportements et la conception du *ground truth*.

3. Enseignements

- Le prompt apparaît comme un paramètre critique : certains écarts ne sont pas liés au modèle, mais aux instructions données.
- Un schéma de granularité raisonnable, couplé à un prompt générique, permet d'obtenir des résultats fiables sans nécessiter une connaissance « atomique » des spécificités documentaires.

- L’analyse statistique page par page révèle des indices sur les exceptions structurelles internes aux documents (choix typographiques ou institutionnels), qui peuvent être significatives pour l’historien.

IV. Conclusion

Ce travail a exploré l’utilisation des grands modèles de langage pour la génération de données structurées à partir de sources historiques, à travers une étude de cas centrée sur les *Tables nominatives* du Sénat français de 1931. L’approche — combinant OCR, structuration guidée par schéma et génération contrainte via LLM — a produit des résultats évalués grâce à une métrique plus adaptée, l’**IMQ**, intégrée dans un protocole d’alignement optimal reliant données de référence et données prédites.

L’introduction de la métrique IMQ s’est révélée essentielle : elle permet d’évaluer la qualité de structuration au-delà des scores classiques de précision/rappel, inadéquats dans ce contexte.

Plusieurs pistes s’ouvrent pour renforcer la robustesse et la généralisation de l’approche :

- **Relier plus directement données extraites et questions de recherche** : il s’agit d’assurer que les hypothèses de réponse formulées à partir des données générées restent robustes dans le temps.
- **Évaluer le prompt lui-même** : cette étape reste à formaliser pour parvenir à un protocole d’évaluation véritablement complet.
- **Repenser la structuration de données** : elle ne doit pas être considérée comme un simple prétraitement neutre, mais comme un choix déterminant pour les analyses historiques possibles.

De ce point de vue, le prompt et le schéma de données apparaissent comme des **méta-paramètres** du système de production de données historiques. Leur génération et leur ajustement doivent être conçus comme faisant partie intégrante de la chaîne de traitement.

Une voie prometteuse consiste à **systématiser et automatiser ce processus de méta-optimisation**, afin de rendre ces approches reproductibles, transparentes et accessibles à des utilisateurs non spécialistes.

Quatrième partie

Conclusion

Annexe A

Le titre très long de la première
annexe

Table des matières

| | |
|--|--------------|
| Résumé | i |
| Remerciements | iii |
| Bibliographie | v |
| Méthodologie historique | v |
| Institutions et politiques patrimoniales | v |
| Humanités numériques | vi |
| Images et numérisation | vii |
| Traitement automatique du langage | vii |
| Philosophie de la technique et médialité | viii |
| | ix |
| Introduction | xi |
| I Des sources sérielles : les Tables Annuelles du Sénat comme cas d’usage | 1 |
| 1 Le <i>Journal Officiel</i> : la parole, la main, la vue et le droit | 3 |
| 1. Les sources sérielles : définition et enjeux | 3 |
| 2. 1.1. Le <i>Journal Officiel</i> : entre publicité et promulgation | 4 |
| 3. 1.2. Archives ou documentation ? La place singulière du <i>Journal Officiel</i> | 4 |
| 4. 1.3. Le <i>Journal Officiel</i> dans son contexte technique et administratif (1921–1940) | 5 |
| 5. 1.4. Les « processus métier » de la publicité parlementaire | 5 |
| 2 Chapitre 2 — Les tables annuelles : des relations entre corpus | 7 |
| 1. 2.1. Les tables dans l’environnement du <i>Journal Officiel</i> | 7 |

| | | |
|----|--|----|
| 2. | 2.2. Forme et organisation des tables | 7 |
| 3. | 2.3. Informations sémantiques et usages | 8 |
| 4. | 2.4. Les tables comme « hub » intercorpus | 8 |
| 5. | Exemple : Les Tables du Sénat, année 1931 | 8 |
| a. | 1. Index des orateurs | 9 |
| b. | 2. Table des matières thématiques | 9 |
| c. | 3. Références législatives et réglementaires | 9 |
| 6. | Analyse | 9 |
| 7. | Numérisation du <i>Journal Officiel</i> : entre politique documentaire, infrastructures techniques et souveraineté archivistique | 10 |

II L'enjeu des données structurées : des sources à la base de données 11

3 Une histoire par les données 13

| | | |
|----|---|----|
| I. | Numériser les sources | 15 |
| 1. | En « mode texte » | 15 |
| 2. | En « mode image » | 18 |
| 3. | La « datafication » | 20 |
| 4. | Pratiques historiennes : sphère technique, sphère sociale | 21 |

4 En passant par le texte : de l'image à la donnée structurée 25

| | | |
|----|---|----|
| I. | La reconnaissance optique de caractères | 25 |
| 1. | Une vue d'ensemble | 25 |
| 2. | Les grandes technologies d'OCR | 31 |
| 3. | CER, WER : métriques pour évaluer la qualité de l'OCR | 32 |
| 4. | Numérisation du <i>Journal Officiel</i> : une politique documentaire partagée entre la BnF et les institutions parlementaires | 34 |

5 Données brutes, données structurées 37

| | | |
|------|--|----|
| I. | Modéliser des données structurées | 38 |
| II. | Produire des données structurées à partir de texte | 39 |
| 1. | Approche à motifs explicites : les ReGex | 40 |
| 2. | Approches extractives : BERT | 41 |
| 3. | Approches génératives : les LLMs | 42 |
| III. | La sortie structurée via LLM pour le <i>Journal Officiel</i> | 44 |
| 1. | Simplicité | 45 |

| | | |
|--|--|-----------|
| 2. | Sortie structurée, génération structurée | 45 |
| III Expérimenter et évaluer pour comprendre : une démarche historienne outillée | | 47 |
| 6 | Evaluer le protocole de capture sémantique | 49 |
| 7 | Expérimentations | 51 |
| 8 | Livrable | 53 |
| I. | Extraction guidée par schéma des interventions parlementaires à partir des index historiques | 53 |
| 1. | Les Tables nominatives du Sénat de 1931 | 53 |
| 2. | Chaîne de traitement pour l'extraction structurée guidée par schéma | 53 |
| 3. | Modélisation des données et définition du schéma | 54 |
| 4. | Construction du prompt pour l'extraction | 55 |
| 5. | Raffinement itératif du schéma et du prompt | 56 |
| II. | Expériences | 56 |
| 1. | Jeu de données | 56 |
| 2. | Protocole d'évaluation des sorties structurées | 57 |
| a. | Distance au niveau des entrées et appariement optimal . . . | 58 |
| b. | Limites des métriques classiques : précision, rappel et F1 . . | 58 |
| c. | Integrated Matching Quality (IMQ) : une métrique robuste | 58 |
| III. | Résultats et analyse | 59 |
| 1. | Variations entre pages | 59 |
| 2. | Comparaison avec OCR « parfait » | 60 |
| 3. | Enseignements | 60 |
| IV. | Conclusion | 61 |
| IV Conclusion | | 63 |
| A | Titre court | 65 |